Medir como el radiólogo: índice cardiotorácico por segmentación con U-Net frente a una CNN de caja negra para detectar cardiomegalia

Juan Sebastian Contreras Avendaño, Junior Romero Lovera, Luis Muñoz Cañabe,
Derly Raúl Oha Quispe, Lourdes Pedraza Palomino
Grupo 6 · Maestría en Inteligencia Artificial, Facultad de Ingeniería Industrial y de Sistemas
Universidad Nacional de Ingeniería, Lima, Perú

***Resumen*—La cardiomegalia se sospecha en la radiografía de tórax con el índice cardiotorácico (ICT), pero en gran parte del Perú no hay un radiólogo que lo informe a tiempo. Comparamos dos formas de automatizarlo con aprendizaje profundo: medir el ICT a partir de una U-Net que segmenta pulmones y corazón, entrenada con máscaras automáticas de CheXmask, o clasificar con una ResNet-50 de caja negra. Usamos 8 776 radiografías de ChestX-ray14 con partición por paciente y el conjunto de prueba oficial (2 354), tres semillas por modelo y contornos humanos (SCR, 147 placas) como referencia. La U-Net midió el ICT con un acuerdo alto frente a los contornos humanos (ICC de 0.945 a 0.951; 0.964 a 0.971 tras ajustarla con 80 placas humanas). Como detector, la ResNet-50 superó al ICT (AUC de 0.892 frente a 0.814). Ambos métodos perdieron rendimiento en placas AP; en el ICT el sesgo se explica por la magnificación y una regresión logística con la vista elevó la especificidad en AP de 0.356 a 0.619. En 300 fotos de 100 radiografías tomadas con dos celulares, ambos perdieron de 0.02 a 0.03 de AUC, pero el ICT cambió de decisión en 4.7–8.3 % de las placas frente a 8.3–13.3 % de la ResNet-50. Medir no gana en exactitud, pero da una cifra que el médico puede ver, revisar y corregir; la publicamos en una aplicación web que corre en el celular.**

***Palabras clave*—aprendizaje profundo, U-Net, índice cardiotorácico, cardiomegalia, radiografía de tórax, etiquetas débiles**

I. Introducción

En el Perú, según el Observatorio de Recursos Humanos en Salud del Ministerio de Salud, hay 495 médicos radiólogos para más de 35 millones de habitantes, y Lima concentra el 54.8 % de los radiólogos y tecnólogos médicos [1]. Al mismo tiempo, la Red Nacional de Telesalud interconecta 3 072 establecimientos y transmite datos e imágenes médicas [2]. La radiografía ya puede viajar desde un puesto de salud alejado; lo que escasea es quien la lea. Una medida automática del corazón, que se pueda revisar y que corra en el celular del médico general, apunta a ese cuello de botella.

El ICT es el cociente entre el ancho máximo del corazón y el ancho interno del tórax; un valor mayor que 0.50 en una placa posteroanterior (PA) sugiere cardiomegalia. Es una medida geométrica: si una red dibuja el corazón y los pulmones, el ICT sale de esos contornos con una regla, igual que lo haría el radiólogo. La alternativa habitual es un clasificador que entrega una probabilidad sin decir de dónde sale.

Este trabajo compara ambas familias del curso en el mismo problema y con las mismas particiones: segmentación con una U-Net [3] y clasificación con una ResNet-50 preentrenada [4]. La entrada es una radiografía frontal de tórax; las salidas son el ICT (y sus componentes) o la probabilidad de cardiomegalia. El éxito se mide en tres frentes: acuerdo con contornos humanos, capacidad de detección (AUC) y estabilidad ante dos fuentes de error del mundo real: la proyección anteroposterior (AP), que agranda el corazón, y la radiografía que llega como foto de celular.

Las contribuciones de este trabajo son:

- Una comparación controlada "medir frente a clasificar" en la que la U-Net se entrena con *máscaras automáticas* (CheXmask) y se evalúa contra *contornos humanos* (SCR).
- La medición del atajo de la proyección AP en ChestX-ray14 para ambos enfoques, con una corrección explícita para el ICT y Grad-CAM para la caja negra.
- Una prueba propia con 300 fotos de celular de 100 radiografías, con marcas fiduciales para enderezarlas, y una aplicación web que mide el ICT en el dispositivo y deja corregir la medida.

El resto del artículo se organiza así: la Sección II revisa trabajos relacionados; la Sección III describe la metodología; la Sección IV presenta los resultados, que se discuten en la Sección V; la Sección VI concluye.

II. Trabajos relacionados

Medir frente a clasificar la cardiomegalia. Sogancioglu *et al.* [5] compararon en ChestX-ray14 un ICT calculado de una segmentación con un clasificador directo y encontraron ventaja para la segmentación (AUC de 0.977 frente a 0.941). Su segmentación se entrenó con anotaciones de corazón y pulmón en 778 placas, y la prueba usó 367 placas etiquetadas por dos radiólogos. Chamveha *et al.* [6] calcularon el ICT con una U-Net a partir de la descomposición clásica en las distancias de la línea media a cada borde del corazón, que usamos aquí; los radiólogos aceptaron sin cambios el 76.5 % de sus medidas. Nuestra diferencia es entrenar la segmentación con máscaras automáticas a escala y medir, además, la robustez a la proyección y a fotos.

Tabla I
RESUMEN DEL CONJUNTO DE DATOS (CHESTX-RAY14, 5 674 PACIENTES)

Partición	Placas	Con cardiomegalia	Sin	AP
Entrenamiento	5 416	1 471	3 945	1 829
Validación	1 006	236	770	357
Prueba (oficial)	2 354	1 069	1 285	1 335

Arquitecturas base. La U-Net [3] combina un codificador y un decodificador con conexiones de salto y es el estándar de segmentación médica; la ResNet [4] introdujo las conexiones residuales y su versión preentrenada en ImageNet es una línea base habitual de clasificación. Grad-CAM [7] pondera los mapas de la última capa convolucional por el gradiente de la clase para mostrar dónde mira la red.

Datos y etiquetas. ChestX-ray14 [8] trae 112 120 radiografías con etiquetas extraídas de los informes. CheXmask [9] publicó máscaras de pulmones y corazón generadas con HybridGNet [10], que codifica la imagen con convoluciones y decodifica los contornos con convoluciones sobre grafos, junto con un índice de calidad por imagen (RCA). Nuestra U-Net aprende, entonces, de las salidas de una red de grafos más reciente: es una destilación hacia una arquitectura más simple que cabe en un navegador. SCR [11] contiene contornos trazados por personas sobre la base JSRT [12], y es nuestra referencia dorada.

Atajos y robustez. Zech *et al.* [13] mostraron que los modelos de radiografías pueden aprender señales del hospital o del equipo en lugar de la enfermedad; la proyección AP, típica de pacientes en cama, es una de esas señales. CheXphoto [14] publicó fotos con celular y transformaciones sintéticas de radiografías para probar la robustez de los clasificadores, pero no incluye medidas geométricas como el ICT.

III. METODOLOGÍA

III-A. Datos

ChestX-ray14 (NIH Clinical Center [8]). Armamos un subconjunto con todas las placas etiquetadas "Cardiomegaly" que tienen máscara en CheXmask y 6 000 placas sin cardiomegalia (con o sin otros hallazgos, no solo "No Finding", para que la red no aprenda "sano frente a enfermo"). La prueba es la lista oficial del NIH; entrenamiento y validación se separaron por *Patient ID*, de modo que ningún paciente aparece en dos particiones (Tabla I). En el subconjunto, el 43.7 % de las placas con cardiomegalia son AP frente al 38.5 % de las sin cardiomegalia: la vista está asociada a la etiqueta.

Máscaras débiles: CheXmask [9] (CC BY 4.0). Decodificamos las máscaras de pulmón derecho, pulmón izquierdo y corazón de las 8 776 placas; 8 666 tienen RCA ≥ 0.7.

Contornos humanos: SCR [11] (CC BY 4.0) sobre 247 radiografías JSRT [12]. Rasterizamos los contornos a máscaras. Usamos 147 placas como prueba dorada y 100 para el ajuste fino de E1c (80 para entrenar y 20 para elegir la época).

Preprocesamiento y aumento. Todas las imágenes se llevan a gris de 256×256 píxeles con reducción por área y se normalizan como $(x/255 - 0.5)/0.25$. En entrenamiento se aplican rotación de $\pm 10°$, escala de 0.9 a 1.1, traslación de ± 5 % y brillo y contraste de ± 15 %. No se voltea la imagen: el corazón está a la izquierda del paciente y el volteo crearía anatomía falsa.

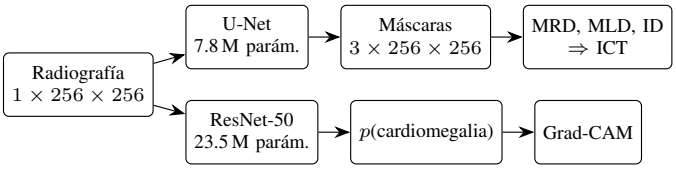


Figura 1. Dos caminos para la misma radiografía: medir el ICT a partir de los contornos (arriba) o clasificar con una caja negra (abajo).

Fotos con celular (E5). Elegimos 100 placas de la prueba oficial, 25 por grupo (PA o AP, con o sin cardiomegalia), y las mostramos en un monitor de 1920×1080 dentro de una lámina con cuatro marcas ArUco en las esquinas y una quinta que codifica el número de placa [15]. Se tomaron 300 fotos: iPhone 16 Pro de frente y con inclinación, y Honor X8b (LLY-LX3) de frente. Cada foto se endereza con una homografía estimada con las esquinas de las marcas visibles (al menos 2 marcas, 8 puntos) y se recorta la radiografía. Como respaldo, se aplicaron seis degradaciones sintéticas a las mismas placas: perspectiva, rotación de 7°, desenfoque, brillo, moiré y compresión JPEG.

III-B. Arquitecturas

La Fig. 1 resume el sistema.

U-Net implementada desde cero (reutilizada del examen parcial del grupo). Tiene cuatro niveles de submuestreo con 32, 64, 128 y 256 canales y un cuello de botella de 512. Cada bloque aplica dos veces convolución 3×3 con relleno, *BatchNorm* y ReLU. Sube con convolución transpuesta 2×2 y concatena el salto; cierra con una convolución 1×1 que da 3 canales: pulmón derecho, pulmón izquierdo y corazón. Cada canal lleva su propia sigmoide, porque el corazón se superpone a los pulmones y las clases no son excluyentes. Tiene 7.76 M de parámetros, todos entrenados.

ResNet-50 [4] preentrenada en ImageNet, con la capa final cambiada por una salida única. La radiografía en gris se repite en tres canales y se normaliza como ImageNet. Usa las mismas imágenes de 256 píxeles, la misma partición y el mismo aumento que la U-Net. Tiene 23.5 M de parámetros, todos ajustados.

III-C. Formulación y función de pérdida

Segmentación. Sea $\hat{y}_{c,i} = \sigma(z_{c,i})$ la probabilidad del píxel i en el canal $c \in \{1, 2, 3\}$ y $y_{c,i} \in \{0, 1\}$ la máscara. La pérdida combina entropía cruzada binaria y Dice por canal:

$$\mathcal{L}_{\text{seg}} = \text{BCE}(\hat{y}, y) + 1 - \frac{1}{3}\sum_{c=1}^{3} \frac{2\sum_i \hat{y}_{c,i} y_{c,i} + \epsilon}{\sum_i \hat{y}_{c,i} + \sum_i y_{c,i} + \epsilon}, \quad (1)$$

con $\epsilon = 1$. El Dice se promedia por canal para que los pulmones, más grandes, no dominen al corazón.

Índice cardiotorácico. Binarizamos cada canal en 0.5 y conservamos su mayor componente conexa. El diámetro interno del tórax ID es la fila con mayor distancia entre el borde externo del pulmón derecho y el del pulmón izquierdo; su punto medio define la línea media x_m. Con $x_{\text{mín}}$ y $x_{\text{máx}}$, los bordes del corazón,

$$\text{MRD} = \max(0, x_m - x_{\text{mín}}), \quad \text{MLD} = \max(0, x_{\text{máx}} - x_m), \tag{2}$$

$$\text{ICT} = \frac{\text{MRD} + \text{MLD}}{\text{ID}}. \tag{3}$$

Si falta alguna estructura, la placa se declara no medible. Con el tamaño de píxel del NIH, MRD se expresa también en centímetros.

Clasificación. Entropía cruzada binaria con peso para la clase positiva $w_+ = N_-/N_+$, calculado en entrenamiento (27 % de cardiomegalia):

$$\mathcal{L}_{\text{cls}} = -\frac{1}{N}\sum_{n=1}^{N}\left[w_+\, y_n \log p_n + (1 - y_n)\log(1 - p_n)\right]. \tag{4}$$

Grad-CAM [7] sobre la última etapa convolucional (`layer4`). Por placa calculamos la energía del mapa dentro del corazón, $E = \sum_i M_i\, h_i / \sum_i M_i$ (h = máscara del corazón), y la dividimos por el área del corazón. Una razón de 1 equivale a un mapa uniforme.

III-D. Experimentos

- **E1, segmentación:** máscaras débiles completas (E1a) frente a filtradas por RCA ≥ 0.7 (E1b) y E1b ajustada con 80 placas humanas (E1c). Se mide el Dice en la prueba dorada SCR.
- **E2, diagnóstico:** AUC del ICT (U-Net), de la ResNet-50 y de dos líneas base: el ICT calculado directamente de las máscaras de CheXmask (sin red) y una regresión logística sobre [ICT, vista AP] ajustada en entrenamiento.
- **E3, acuerdo clínico:** ICT de la U-Net frente al ICT de los contornos humanos en SCR, con ICC(A,1) de McGraw y Wong [16] y límites de Bland-Altman [17].
- **E4, proyección:** AUC por vista; una ResNet-50 entrenada solo con placas PA; la "fuga de vista", que es el AUC del puntaje para separar AP de PA *solo entre placas sin cardiomegalia* (0.5 = el puntaje no codifica la vista); y Grad-CAM.
- **E5, fotos:** para cada foto y cada semilla, cambio del ICT y de la probabilidad frente a la placa original, porcentaje de decisiones que cambian y AUC. La comparación entre la foto enderezada y la recortada sin enderezar usa las mismas placas.
- **E6, lado derecho:** AUC de MRD/ID y de MLD/ID por separado, y su distribución en aciertos y errores del ICT.

III-E. Entrenamiento y métricas

Ambos modelos usan AdamW [18] con decaimiento de pesos 10^{-4}, tasa de aprendizaje con política de un ciclo (*OneCycle*) y precisión mixta. La U-Net entrena 30 épocas con lote de 16 y tasa máxima de 10^{-3}; el ajuste E1c, 30 épocas con lote de 8 y 2×10^{-4}. La ResNet-50 entrena 12 épocas con lote de 32 y 3×10^{-4}. La época se elige en validación: el Dice medio con máscaras débiles (U-Net), el Dice en las 20 placas humanas reservadas (E1c) o el AUC (ResNet). El umbral de la ResNet es el de Youden [19] en validación; el del ICT es el clínico de 0.50, sin ajustar. La prueba no se usó para elegir nada. Cada experimento se repite con las semillas 0, 1 y 2 y se reporta media $\pm$ desviación estándar. Reportamos AUC, sensibilidad, especificidad y F1, porque la prueba no está balanceada (45 % de cardiomegalia).

Hardware. Kaggle con dos GPU Tesla T4. El primer día entrenamos 62.6 min (dos U-Net y el ajuste). El segundo día, 150.6 min de U-Net y 38.2 min de ResNet-50 con Grad-CAM, en paralelo. En total fueron unas 4.2 horas de GPU. E5 y E6 corrieron en el CPU de una laptop: E5 tardó 35.5 min para 6 modelos y 13 condiciones de 73 a 100 placas.

Tabla II
DETECCIÓN DE CARDIOMEGALIA EN LA PRUEBA OFICIAL (2 354 PLACAS; MEDIA $\pm$ D. E., 3 SEMILLAS)

Método	AUC	Sens.	Esp.	F1
ResNet-50 (PA + AP)	**0.892 ± 0.010**	0.830	**0.786**	**0.795**
ResNet-50 (solo PA)	0.865 ± 0.014	0.771	0.783	0.759
ICT, U-Net E1b	0.814 ± 0.001	0.925	0.488	0.728
ICT + vista (reg. log.)	0.810 ± 0.001	0.834	0.615	0.726
ICT, CheXmask (sin red)	0.801	0.930	0.471	0.725
ICT, U-Net E1c	0.796 ± 0.006	**0.955**	0.407	0.716

Sensibilidad, especificidad y F1 al umbral de Youden en validación. ICT al umbral clínico de 0.50: sensibilidad 0.918, especificidad 0.504.

Tabla III
SEGMENTACIÓN Y ACUERDO DEL ICT EN LA PRUEBA DORADA SCR (147 PLACAS; 3 SEMILLAS)

Variante	Dice corazón	Dice medio	Error ICT	ICC(A,1)
E1a débil, todas	0.936 ± 0.001	0.962 ± 0.001	0.012	0.948–0.953
E1b débil, RCA ≥ 0.7	0.936 ± 0.001	0.961 ± 0.001	0.012	0.945–0.951
E1c E1b + 80 humanas	**0.951 ± 0.001**	**0.971 ± 0.000**	**0.010**	**0.964–0.971**

Error ICT = error absoluto medio frente al ICT de los contornos humanos. ICC: rango entre semillas.

IV. RESULTADOS

IV-A. Comparación con las líneas base

La ResNet-50 detecta mejor que el ICT (Tabla II). El ICT de la U-Net supera al calculado directamente de CheXmask (0.814 frente a 0.801), y la U-Net ajustada con contornos humanos, que mide mejor (Tabla III), diagnostica peor (0.796).

IV-B. Segmentación, acuerdo clínico y ablación de las etiquetas

Filtrar CheXmask por calidad no cambió nada medible: solo 110 de 8 776 máscaras quedan por debajo de RCA 0.7. El ajuste con 80 placas humanas subió el Dice del corazón de 0.936 a 0.951 y el ICC a 0.964–0.971. En E1c, el sesgo del ICT frente a los humanos está entre -0.0035 y -0.0005 y los límites de Bland-Altman son de alrededor de ± 0.03. En las tres variantes, la decisión ICT ≥ 0.50 coincide con la de los contornos humanos en el 93–96 % de las placas.

Tabla IV
EFECTO DE LA PROYECCIÓN (PRUEBA OFICIAL: 1 019 PA, 1 335 AP)

Método	AUC PA	AUC AP	Esp. AP	Fuga de vista
ResNet-50 (PA + AP)	0.944	0.845	0.750	0.646 ± 0.055
ResNet-50 (solo PA)	0.936	0.795	0.731	0.710 ± 0.045
ICT, U-Net	0.864	0.776	0.356	0.691 ± 0.011
ICT + vista	0.864	0.776	0.619	**0.493 ± 0.011**

Esp. AP al umbral de Youden. Fuga de vista: AUC para separar AP de PA entre placas sin cardiomegalia; 0.5 = no codifica la vista.

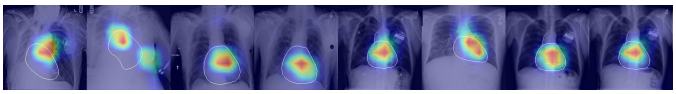


Figura 2. Grad-CAM de la ResNet-50 (semilla 0) en placas de prueba; contorno blanco: corazón de CheXmask.

IV-C. Proyección AP e interpretabilidad

Todos los métodos rinden menos en AP (Tabla IV). En el ICT, la especificidad en AP cae a 0.356: la magnificación hace que muchos corazones normales pasen de 0.50. Como la causa es conocida, se corrige con la vista; la regresión logística baja la fuga a 0.493 y sube la especificidad en AP a 0.619. La ResNet-50 entrenada solo con PA pierde 0.141 de AUC al pasar a AP, frente a 0.099 de la entrenada con ambas vistas.

Cuando la ResNet-50 predice "cardiomegalia", la energía de Grad-CAM dentro del corazón es de 4.3 a 6.4 veces la que tendría un mapa uniforme, acierte o no. En los negativos correctos, la razón baja a 1.2–4.3 (rangos entre corridas y vistas). La Fig. 2 muestra ejemplos; en uno se ve el rótulo "PORTABLE", una pista de la vista AP que está a la vista de la red.

Separando por acierto, los falsos positivos de la ResNet-50 (PA + AP) concentran en el corazón la misma energía que los verdaderos positivos (razón de 5.3–6.2 frente a 5.4–6.2), y del 74 al 82 % del mapa cae dentro del tórax, como en los aciertos (79–85 %). En los verdaderos negativos esa fracción baja a 38–52 % y la razón a 1.5–3.3; los falsos negativos quedan en medio (2.7–4.4). La tasa de falsos positivos es mayor en AP que en PA en las tres semillas (0.13–0.40 frente a 0.11–0.24), y en la ResNet-50 entrenada solo con PA llega a 0.34–0.65 en AP.

IV-D. Fotos con celular

Se leyeron todas las fotos (301; una placa se fotografió dos veces con el Honor) y las 100 placas quedaron cubiertas con cada celular (Tabla V). Ambos métodos pierden entre 0.02 y 0.03 de AUC. El ICT cambia de decisión en menos placas que la ResNet-50, y lo hace en casos limítrofes: las 59 mediciones de 899 que cruzan el umbral estaban a una mediana de 0.013 de 0.50, frente a 0.056 en todas. El cambio absoluto mediano del ICT fue de 0.010 a 0.012. Sobre las mismas placas, enderezar la foto aportó poco (ICT: 5.9 frente a 8.2 % de decisiones que cambian con el Honor; 10.3 frente a 10.7 % con el iPhone inclinado); la inclinación lograda fue moderada. Las degradaciones sintéticas subestimaron el efecto real sobre el ICT.

Tabla V
FOTOS CON CELULAR: 100 PLACAS, 3 SEMILLAS POR MODELO (MEDIA ± D. E.)

	ICT (U-Net)		ResNet-50	
Condición	AUC	Cambia	AUC	Cambia
Original	0.827 ± 0.008	–	0.899 ± 0.020	–
iPhone, frente	0.801 ± 0.009	6.7 %	0.872 ± 0.020	13.3 %
iPhone, inclinada	0.797 ± 0.014	8.3 %	0.883 ± 0.010	10.3 %
Honor, frente	0.812 ± 0.014	4.7 %	0.881 ± 0.011	8.3 %
Sintéticas (6)	0.814–0.833	2.0–5.3 %	0.891–0.908	4.3–22.3 %

"Cambia": placas cuya decisión (ICT 0.50; ResNet, umbral de Youden) difiere de la original.



Figura 3. Aplicación web: contornos de la U-Net, línea media, bordes del corazón y del tórax, ICT y aviso de calidad.

IV-E. El lado derecho del corazón

Por separado, MLD/ID tiene un AUC de 0.735 ± 0.003 y MRD/ID uno de 0.697 ± 0.003; su suma (el ICT) da 0.814. Los falsos negativos del ICT no esconden un lado derecho grande: su MRD/ID mediano (0.138–0.154) se parece al de los verdaderos negativos (0.137–0.148) y está lejos del de los verdaderos positivos (0.188–0.204). Solo el 13–16 % de los falsos negativos supera el percentil 90 de los verdaderos negativos. En los cuatro grupos, MRD en centímetros es mayor en AP que en PA (p. ej., 4.59 frente a 4.18 cm en los verdaderos negativos).

IV-F. Aplicación y costo de inferencia

La U-Net se exportó a ONNX (31 MB) y se verificó contra PyTorch: la diferencia máxima de probabilidad fue de 2.5×10^{-6} y el 100 % de los píxeles coincidió. La aplicación web corre en el navegador sin enviar la imagen (Fig. 3). En una laptop, una medición tarda de 1.7 a 3.2 s. Para una foto, el usuario marca las cuatro esquinas de la radiografía; las líneas de la medida se pueden arrastrar para corregirla. En dos ejemplos y en una foto real da el mismo ICT que el código de Python. La aplicación avisa cuando la imagen es de baja calidad: el criterio que predijo error en E5 fue la incertidumbre de la red (umbral = percentil 99 de las 100 placas originales). De las 300 fotos corregidas, avisó en 25, y en ellas el ICT cambió de lado del 0.50 en el 20 % frente al 2.9 % en el resto.

V. Discusión

V-A. Por qué la caja negra detecta mejor

La hipótesis de que medir detectaría al menos tan bien como clasificar no se sostiene: la ResNet-50 supera al ICT en 0.078 de AUC (0.070 a 0.090 según la semilla; 0.080 en PA y 0.069 en AP), y gana en cada semilla y en cada vista. Proponemos tres explicaciones, que los datos apoyan pero no prueban. Primera, el ICT reduce la placa a un cociente de anchos, mientras que la ResNet-50 ve toda la imagen y puede aprovechar la forma de la silueta, los vasos o los hallazgos que acompañan a la cardiomegalia y, como muestra E4, la propia vista. Segunda, la etiqueta del NIH no es "ICT > 0.50": sale del texto del informe, y al umbral clínico la mitad de las placas sin cardiomegalia lo superan (especificidad de 0.504; 0.377 en AP). No es un umbral mal puesto, porque el de Youden en validación cae en 0.495–0.497; es que las distribuciones del ICT con y sin la etiqueta se solapan. El ICT mide bien una cosa que no coincide del todo con lo que la etiqueta llama cardiomegalia. Tercera, Soganciogluet *al.* [5], donde la segmentación ganó, evaluaron con etiquetas puestas por dos radiólogos y no con las extraídas del informe, y entrenaron con 778 placas anotadas; la nuestra aprende de máscaras automáticas, lo que abarata la escala pero la ata a los sesgos de HybridGNet. Ambas diferencias son compatibles con que el resultado se invierta, pero no las aislamos.

E1c ilustra la segunda razón. Ajustar la U-Net con 80 contornos humanos la acercó a los humanos (ICC de 0.945–0.951 a 0.964–0.971 y sesgo casi nulo) y, aun así, bajó el AUC de 0.814 a 0.796 y la especificidad en AP de 0.377 a 0.247 al umbral de 0.50. Medir mejor no es diagnosticar mejor cuando la etiqueta no es la medida. Hay además un efecto de dominio: la mejora se midió en placas JSRT, las mismas de las que salieron los 80 contornos de ajuste, y la pérdida, en ChestX-ray14. No aislamos cuál de los dos efectos pesa más.

V-B. Lo que se gana al medir

El ICT detecta peor, pero sus errores tienen nombre. En AP, el corazón se ve más grande por la geometría de la toma; E6 lo confirma, porque MRD en centímetros es mayor en AP incluso en los verdaderos negativos. Como la causa es conocida, una regresión logística con la vista la corrige: la fuga baja de 0.691 a 0.493 y la especificidad en AP sube de 0.356 a 0.619, a costa de 0.004 de AUC. La ResNet-50 también codifica la vista (fuga de 0.646, y de 0.710 si solo vio placas PA), pero no hay una fórmula que la quite, porque no sabemos qué rasgos la llevan.

Las fotos con celular separan aún más los dos enfoques. Ambos pierden lo mismo de AUC, pero el ICT cambia de decisión en menos placas y solo cerca del umbral, donde cualquier medida es dudosa: las placas que cambian estaban a 0.013 de 0.50. Con las fotos reales, la ResNet-50 cambia de decisión hasta en el 13.3 % de las placas, y nada en su salida avisa cuáles son. Las degradaciones sintéticas subestimaron el efecto real sobre el ICT, así que no bastan para validar un sistema que recibirá fotos.

Grad-CAM no ofrece esa garantía. Los falsos positivos de la ResNet-50 miran al corazón con la misma intensidad que los aciertos, de modo que el mapa muestra *dónde* mira la red pero no permite saber si se equivocó. En el ICT, en cambio, el error se ve en la placa: si la línea del borde derecho cae fuera del corazón, el médico la arrastra y el número cambia. Esa es la diferencia práctica entre explicar y medir.

E6 delimita lo que el ICT no ve. La mitad derecha (MRD/ID) separa peor que la izquierda (AUC de 0.697 frente a 0.735), y los falsos negativos no esconden un lado derecho agrandado: su MRD/ID es como el de los verdaderos negativos. El ICT frontal no sirve para sospechar crecimiento del ventrículo derecho; para eso haría falta la placa lateral.

V-C. Limitaciones y sesgos

- **Etiquetas.** Las de ChestX-ray14 se extrajeron de informes con procesamiento de lenguaje y tienen ruido; no medimos cuánto en nuestro subconjunto.
- **Población.** ChestX-ray14 viene de un hospital de EE. UU. y JSRT/SCR de Japón. No evaluamos placas peruanas, y el umbral de 0.50 viene de poblaciones de llanura; no sabemos si vale para quien vive en altura.
- **Fotos.** Las 300 fotos son de radiografías en un monitor, no de placas físicas en un negatoscopio; se tomaron en una sola sesión, con dos celulares y un operador, sobre 100 placas balanceadas por grupo.
- **Referencia dorada.** El acuerdo clínico se mide en 147 placas JSRT, todas PA y digitalizadas de película; no hay contornos humanos en placas AP.
- **Aplicación.** Para una foto, las esquinas se marcan a mano; la medida en un celular real no se ha probado con usuarios.

V-D. Impacto y uso responsable

El uso que proponemos es de apoyo: una segunda lectura que da una cifra y la muestra sobre la placa, no un diagnóstico. La aplicación procesa la imagen en el dispositivo y no la envía a ningún servidor, lo que evita mover datos clínicos. Los riesgos son concretos: aplicar el umbral de 0.50 a placas AP sin corregir multiplica los falsos positivos; confiar en la probabilidad de la ResNet-50 sin mirar la placa invita al sesgo de automatización; y usar cualquiera de los dos en una población no evaluada traslada sesgos que aquí no medimos. No es un dispositivo médico ni ha pasado una validación clínica.

VI. Conclusiones

Una U-Net entrenada solo con máscaras automáticas mide el índice cardiotorácico con un ICC de 0.945–0.951 frente a contornos humanos, que sube a 0.964–0.971 con solo 80 de ellos. Esa medida, aunque detecta cardiomegalia peor que una ResNet-50, falla de forma predecible: su error en placas AP tiene causa física y se corrige con la vista, y ante una foto de celular solo cambia de decisión cerca del umbral. La caja negra acierta más, pero codifica la vista, cambia más decisiones con las fotos y su mapa de Grad-CAM se ve igual cuando acierta que cuando falla. Para un servicio sin radiólogo, la elección

no es solo de exactitud sino de qué error puede revisar quien usa la herramienta.

Como trabajo futuro planteamos: (1) validar con placas peruanas y con el ICT medido por radiólogos, incluido un umbral propio por vista y por altitud; (2) combinar ambos enfoques en la aplicación, con la ResNet-50 como alerta y el ICT como explicación revisable; (3) detectar las esquinas de la placa de forma automática y probar fotos de placas físicas; y (4) comparar la U-Net con HybridGNet y con modelos de base de tipo Transformer como fuentes de máscaras.

Contribuciones

Integrante	Tareas en las que participó
Juan Sebastian Contreras Avendaño	
Junior Romero Lovera	
Luis Muñoz Cañabe	
Derly Raúl Oha Quispe	
Lourdes Pedraza Palomino	

Disponibilidad de código y uso de herramientas de IA

Código y resultados: https://github.com/loupv99/corazon-v2. Aplicación: https://loupv99.github.io/corazon-v2/. Pesos de PyTorch de las 15 corridas (U-Net E1a, E1b y E1c; ResNet-50 E2 y E4; semillas 0, 1 y 2) con su SHA-256: https://github.com/loupv99/corazon-v2/releases/tag/v1.0-pesos. El mejor modelo de segmentación es la U-Net E1b de semilla 1, elegida por Dice de validación (0.9596), que es la que usa la aplicación.

Referencias

[1] Panamericana Televisión, "Cuatro regiones cierran 2025 sin patólogos y Lima concentra casi la mitad de oncólogos," https://panamericana.pe/locales/459222-cuatro-regiones-cierran-2025-patologos-lima-concentra-casi-mitad-oncologos, 2025, con datos del Observatorio de Recursos Humanos en Salud, MINSA. Consultado el 4 de noviembre de 2026.

[2] ——, "Perú lidera la telesalud en América Latina: 9 millones de atenciones y red nacional de 3 072 establecimientos interconectados," https://panamericana.pe/salud/464916-peru-lidera-telesalud-america-latina-9-millones-atenciones-red-nacional-3-072-establecimientos-interconectados, 2026, con datos del MINSA. Consultado el 4 de noviembre de 2026.

[3] O. Ronneberger, P. Fischer, and T. Brox, "U-Net: Convolutional networks for biomedical image segmentation," in *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, ser. LNCS, vol. 9351, 2015, pp. 234–241.

[4] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 770–778.

[5] E. Sogancioglu, K. Murphy, E. Calli, E. T. Scholten, S. Schalekamp, and B. van Ginneken, "Cardiomegaly detection on chest radiographs: Segmentation versus classification," *IEEE Access*, vol. 8, pp. 94 631–94 642, 2020.

[6] I. Chamveha, T. Promwiset, T. Tongdee, P. Saiviroonporn, and W. Chaisangmongkon, "Automated cardiothoracic ratio calculation and cardiomegaly detection using deep learning approach," arXiv:2002.07468, 2020.

[7] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra, "Grad-CAM: Visual explanations from deep networks via gradient-based localization," in *Proc. IEEE Int. Conf. Computer Vision (ICCV)*, 2017, pp. 618–626.

[8] X. Wang, Y. Peng, L. Lu, Z. Lu, M. Bagheri, and R. M. Summers, "ChestX-ray8: Hospital-scale chest X-ray database and benchmarks on weakly-supervised classification and localization of common thorax diseases," in *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, 2017, pp. 3462–3471.

[9] N. Gaggion, C. Mosquera, L. Mansilla, J. M. Saidman, M. Aineseder, D. H. Milone, and E. Ferrante, "CheXmask: a large-scale dataset of anatomical segmentation masks for multi-center chest x-ray images," *Scientific Data*, vol. 11, no. 1, p. 511, 2024.

[10] N. Gaggion, L. Mansilla, C. Mosquera, D. H. Milone, and E. Ferrante, "Improving anatomical plausibility in medical image segmentation via hybrid graph neural networks: applications to chest x-ray analysis," *IEEE Transactions on Medical Imaging*, vol. 42, no. 2, pp. 546–556, 2023.

[11] B. van Ginneken, M. B. Stegmann, and M. Loog, "Segmentation of anatomical structures in chest radiographs using supervised methods: a comparative study on a public database," *Medical Image Analysis*, vol. 10, no. 1, pp. 19–40, 2006.

[12] J. Shiraishi, S. Katsuragawa, J. Ikezoe, T. Matsumoto, T. Kobayashi, K.-i. Komatsu, M. Matsui, H. Fujita, Y. Kodera, and K. Doi, "Development of a digital image database for chest radiographs with and without a lung nodule: receiver operating characteristic analysis of radiologists' detection of pulmonary nodules," *American Journal of Roentgenology*, vol. 174, no. 1, pp. 71–74, 2000.

[13] J. R. Zech, M. A. Badgeley, M. Liu, A. B. Costa, J. J. Titano, and E. K. Oermann, "Variable generalization performance of a deep learning model to detect pneumonia in chest radiographs: A cross-sectional study," *PLOS Medicine*, vol. 15, no. 11, p. e1002683, 2018.

[14] N. A. Phillips, P. Rajpurkar, M. Sabini, R. Krishnan, S. Zhou, A. Pareek, N. M. Phu, C. Wang, M. Jain, N. D. Du, S. Q. Truong, A. Y. Ng, and M. P. Lungren, "CheXphoto: 10,000+ photos and transformations of chest X-rays for benchmarking deep learning robustness," in *Proc. Machine Learning for Health (ML4H), PMLR*, vol. 136, 2020, pp. 318–327.

[15] S. Garrido-Jurado, R. Muñoz-Salinas, F. J. Madrid-Cuevas, and M. J. Marín-Jiménez, "Automatic generation and detection of highly reliable fiducial markers under occlusion," *Pattern Recognition*, vol. 47, no. 6, pp. 2280–2292, 2014.

[16] K. O. McGraw and S. P. Wong, "Forming inferences about some intraclass correlation coefficients," *Psychological Methods*, vol. 1, no. 1, pp. 30–46, 1996.

[17] J. M. Bland and D. G. Altman, "Statistical methods for assessing agreement between two methods of clinical measurement," *The Lancet*, vol. 327, no. 8476, pp. 307–310, 1986.

[18] I. Loshchilov and F. Hutter, "Decoupled weight decay regularization," in *Int. Conf. Learning Representations (ICLR)*, 2019.

[19] W. J. Youden, "Index for rating diagnostic tests," *Cancer*, vol. 3, no. 1, pp. 32–35, 1950.