Universidad Nacional de Ingeniería · FIIS · Maestría en Inteligencia Artificial
MIA-203 Redes Neuronales y Aprendizaje Profundo · Examen final

Medir como el radiólogo

Índice cardiotorácico con **U-Net** frente a una **CNN de caja negra** para detectar cardiomegalia

Grupo 6
Juan Sebastian Contreras Avendaño · Junior Francesco Romero Lovera · Luis Muñoz Cañabe
Derly Raúl Oha Quispe · Lourdes Pedraza Palomino

Lima, 7 de noviembre de 2026 · github.com/loupv99/corazon-v2

Contexto: un siglo midiendo el corazón en la placa

Contexto y antecedentes

1919 — **Danzer** define el ICT: si pasa de 0.50, el corazón es sospechoso. Se mide a mano.

2006 — **SCR**: personas trazan pulmones y corazón en 247 placas JSRT.

2015–16 — **U-Net** segmenta con pocos datos; **ResNet** entrena redes muy profundas.

2017 — **ChestX-ray8/14**: 108 948 placas con etiquetas sacadas del informe.

2020 — **Sogancioglu**: medir gana a clasificar (AUC 0.977 vs. 0.941) con anotación humana.

2024 — **CheXmask**: 657 566 máscaras automáticas (HybridGNet).

Y en el Perú

495 radiólogos para más de 35 millones

54.8 % de radiólogos y tecnólogos, en Lima

3 072 establecimientos en la Red de Telesalud

La placa ya puede viajar; lo que falta es quien la lea.

Fuentes: Danzer 1919 · Wang *et al.* 2017 · Sogancioglu *et al.* 2020 · Gaggion *et al.* 2024 · MINSA, vía Panamericana (2025, 2026)

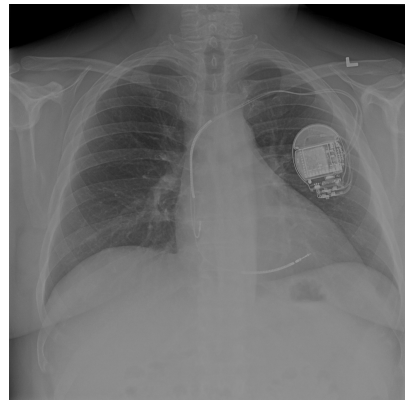
El problema: ¿el corazón está agrandado?

Problema y motivación

- La cardiomegalia se sospecha con el **índice cardiotorácico**:

$$\text{ICT} = \frac{\text{ancho del corazón}}{\text{ancho interno del tórax}}$$

- **ICT $>$ 0.50** en placa PA sugiere cardiomegalia.
- Es una *medida*: el radiólogo traza líneas y divide. Sin radiólogo, la placa espera.
- Dos caminos con aprendizaje profundo: **medir** el ICT con contornos o **clasificar** la placa entera.



Placa de prueba de ChestX-ray14 (NIH)

Pregunta, hipótesis y contribuciones

Problema y motivación

¿Una red que **mide** como el radiólogo detecta tan bien como una que **clasifica** sin explicar? ¿Y cuál falla mejor?

Hipótesis: medir detecta al menos igual, y sus errores se pueden ver y corregir.

1 **Medir frente a clasificar, en igualdad**

Mismas placas, partición y aumento; 3 semillas. U-Net con *máscaras automáticas*, evaluada con *contornos humanos*.

→ **E1, E2, E3**

2 **El atajo de la vista AP**

¿Las dos redes usan la proyección en vez del corazón? Corrección explícita para el ICT; Grad-CAM para la caja negra.

→ **E4, E6**

3 **Datos y aplicación propios**

300 fotos con celular de 100 placas, con marcas ArUco para enderezarlas. App web que mide en el teléfono y deja corregir.

→ **E5**

Trabajos relacionados (1/2): arquitecturas y datos

Trabajos relacionados

Trabajo	Metodología	Principales hallazgos	Aporte al conocimiento	En qué nos diferenciamos
Ronneberger, 2015 U-Net	Codificador-decodificador con saltos; aumento de datos fuerte	Segmenta bien con muy pocas imágenes; ganó ISBI 2015	Segmentación precisa con pocos datos	**La usamos para medir el ICT**, entrenada con máscaras automáticas
He, 2016 ResNet	Bloques residuales $y = F(x) + x$, hasta 152 capas	3.57 % de error en ImageNet; 1.er puesto en ILSVRC 2015	Redes muy profundas que sí se optimizan	ResNet-50 como **caja negra de referencia**
Selvaraju, 2017 Grad-CAM	Gradientes sobre la última capa convolucional, sin reentrenar	Localiza regiones relevantes y revela sesgos del conjunto	Explicación visual para cualquier CNN	**La cuantificamos** en aciertos y en errores
Wang, 2017 ChestX-ray8/14	108 948 placas de 32 717 pacientes; etiquetas del informe con PLN	Detecta con etiquetas débiles, pero leer la placa sigue siendo difícil	Primera base pública grande de tórax	Su etiqueta no equivale a ICT > 0.50 (esp. 0.504)

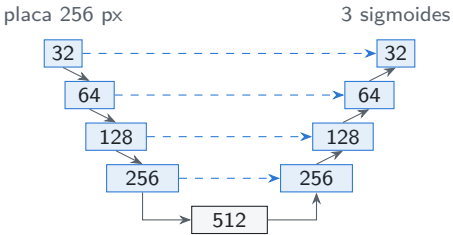
Trabajos relacionados (2/2): cardiomegalia y robustez

Trabajos relacionados

Trabajo	Metodología	Principales hallazgos	Aporte al conocimiento	En qué nos diferenciamos
Sogancioglu, 2020	Segmentación (778 anotadas) vs. clasificación (65 000)	AUC 0.977 frente a 0.941, en 367 placas etiquetadas por 2 radiólogos	Medir gana con 100 veces menos anotaciones	Etiqueta del informe y **máscaras automáticas**: gana clasificar
Chamveha, 2020	U-Net con VGG16; ICT $= (\text{MRD} + \text{MLD})/\text{ID}$	Radiólogos aceptan sin cambios el 76.5 % de las medidas	ICT automático usable en el informe	**MRD y MLD por separado** (E6); vista AP y fotos
Gaggion, 2023–24 HybridGNet, CheXmask	Conv. + grafos; 657 566 máscaras	Contornos plausibles donde otros modelos fallan	Máscaras anatómicas a gran escala	Las **destilamos en una U-Net** para el navegador
Zech, 2018; **Phillips, 2020** (CheXphoto)	CNN en 3 hospitales (158 323 placas); fotos con celular y sintéticas	La CNN reconoce el hospital (99.95 %, NIH); CheXphoto: conjunto de robustez	Atajos del origen; escenario de fotos	Atajo de la **vista AP** en ambos enfoques; fotos propias con ArUco

Fundamento: por qué estas dos arquitecturas

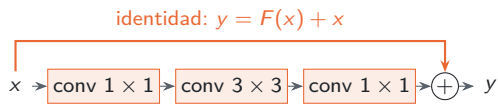
U-Net — medir



cuello de 16 px: contexto de toda la placa
- - -→ saltos: devuelven el detalle del borde

- El ICT depende del borde: 3 px de error en 256 cambian el ICT en ∼0.01.
- Salida **verificable**: contornos que el médico ve y corrige.

ResNet-50 — clasificar



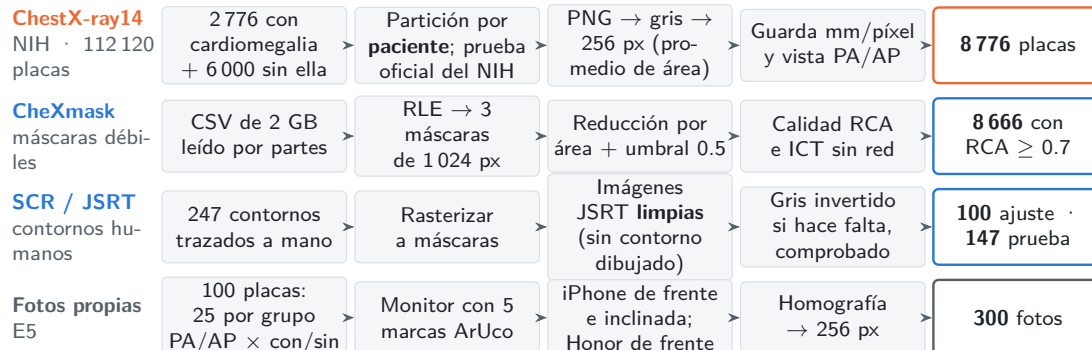
Grad-CAM sobre la última capa:

$$L = \mathrm{ReLU}\big(\textstyle\sum_k \alpha_k A^k\big), \quad \alpha_k = \frac{1}{Z}\sum_{i,j} \frac{\partial y}{\partial A^k_{ij}}$$

- Preentrenada en ImageNet: buen punto de partida con 5 416 placas.
- Ve toda la placa: puede usar señales que el ICT ignora… y atajos.

Preparación de datos: de cuatro fuentes a un mismo formato

DATOS



Salida común: arrays de 256 px (pulmón derecho, izquierdo, corazón) + una tabla por placa. Una sola vez, ∼20 min en Kaggle.

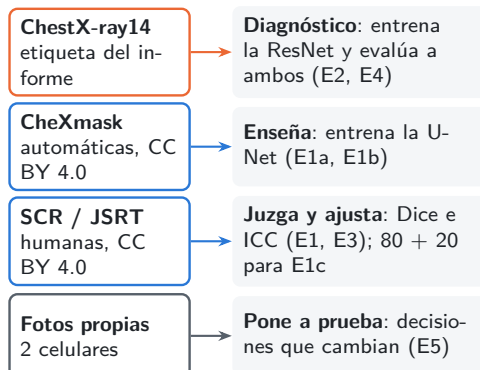
Datos: tres fuentes, una partición sin fuga

Datos

ChestX-ray14	Placas	Cardio.	AP
Entrenamiento	5 416	1 471	1 829
Validación	1 006	236	357
Prueba (oficial NIH)	2 354	1 069	1 335

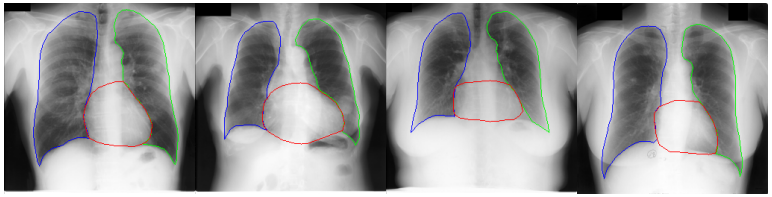
- Partición por **paciente** (5 674): nadie aparece en dos particiones.
- Negativos con y sin otros hallazgos: la red no aprende "sano vs. enfermo".
- La vista está asociada a la etiqueta: 43.7 % AP en cardiomegalia frente a 38.5 % sin ella.

Qué papel cumple cada fuente

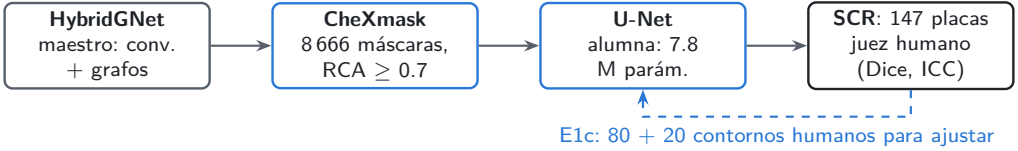


Etiquetas débiles, referencia humana

Datos



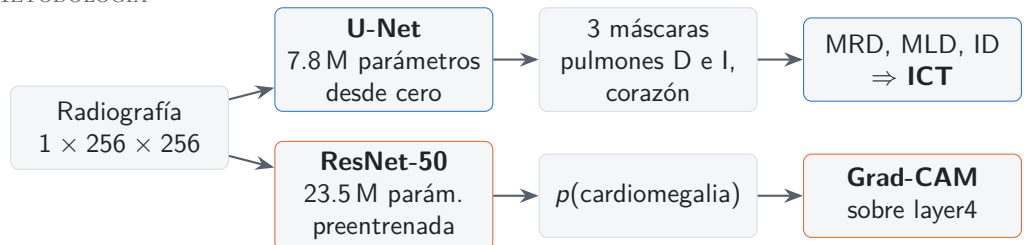
Contornos humanos de SCR rasterizados (azul: pulmón derecho; verde: izquierdo; rojo: corazón)



Una destilación hacia una red que cabe en un navegador. Sin volteo horizontal en el aumento: el corazón está a la izquierda del paciente.

Arquitectura del sistema

Metodología



U-Net: 4 niveles (32–256 canales) + cuello de 512; cada bloque = 2 × (conv 3 × 3, BatchNorm, ReLU); sube con conv. transpuesta y concatena el salto; salida 1 × 1 con 3 sigmoides.

ResNet-50: capa final cambiada por una salida; gris repetido en 3 canales; mismas imágenes, partición y aumento que la U-Net.

Formulación: pérdida y medida

Metodología

Segmentación: BCE + Dice promediado por canal

$$\mathcal{L}_{\text{seg}} = \text{BCE}(\hat{y}, y) + 1 - \frac{1}{3}\sum_{c=1}^{3} \frac{2\sum_i \hat{y}_{c,i} y_{c,i} + \epsilon}{\sum_i \hat{y}_{c,i} + \sum_i y_{c,i} + \epsilon}$$

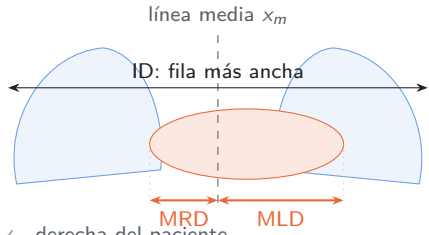
Promediar por canal evita que los pulmones, más grandes, dominen al corazón.

Clasificación: BCE con peso $w_+ = N_-/N_+$

$$\mathcal{L}_{\text{cls}} = -\frac{1}{N}\sum_n \Big[w_+ y_n \log p_n + (1-y_n)\log(1-p_n)\Big]$$

El peso compensa que hay menos placas con cardiomegalia.

Del contorno al número



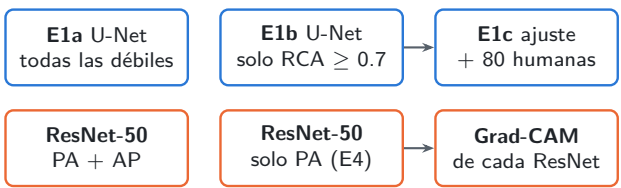
Umbral 0.5 + mayor componente → ID y x_m en la fila más ancha → MRD $= x_m - x_{\text{mín}}$, MLD $= x_{\text{máx}} - x_m$ → $\text{ICT} = \dfrac{\text{MRD} + \text{MLD}}{\text{ID}}$

Si falta una estructura, la placa queda como *no medible*.

Entrenamiento y costo

Metodología

cada caja × 3 semillas (0, 1, 2) ⇒ media ± D. E.

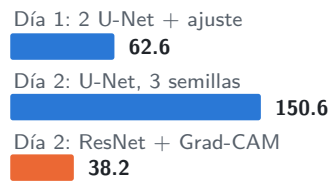


	U-Net	Ajuste E1c	ResNet-50
Épocas · lote	30 · 16	30 · 8	12 · 32
Tasa máx.	10^{-3}	2×10^{-4}	3×10^{-4}
Elige época por	Dice val.	Dice 20 humanas	AUC val.

AdamW (decaimiento 10^{-4}), OneCycle, precisión mixta. Aumento: rotación ±10°, escala 0.9–1.1, traslación ±5 %, brillo/contraste ±15 %.

Minutos de GPU

Kaggle, 2 × Tesla T4



4.2 h de GPU

Umbral de la ResNet: Youden en validación. ICT: **0.50 clínico**, sin ajustar. **La prueba no se usó para elegir nada.** E5 y E6, en el CPU de una laptop.

Diseño experimental

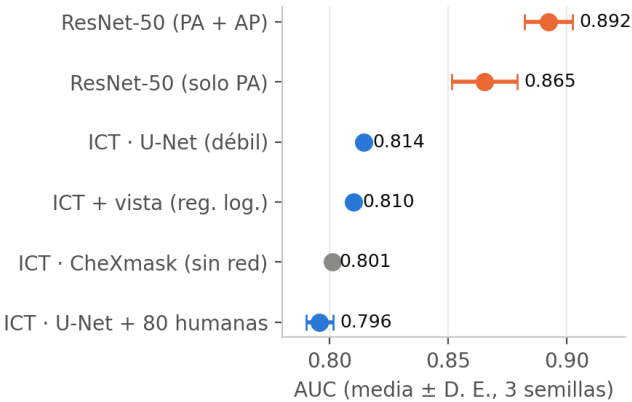
Metodología

Experimento	Qué se compara	Métrica
E1 Ablación de etiquetas	Débiles todas / filtradas RCA ≥ 0.7 / + 80 humanas	Dice en SCR
E2 Línea base	ICT U-Net, ResNet-50, ICT de CheX-mask sin red, reg. log. [ICT, vista]	AUC, sens., esp., F1
E3 Acuerdo clínico	ICT de la U-Net vs. ICT de contornos humanos	ICC(A,1), Bland-Altman
E4 Proyección	AUC por vista; ResNet solo PA; fuga de vista; Grad-CAM	AUC PA/AP, fuga
E5 Fotos	Original vs. 3 condiciones reales + 6 sintéticas	% de decisiones que cambian, AUC
E6 Lado derecho	MRD/ID y MLD/ID por separado	AUC, aciertos vs. errores

Fuga de vista = AUC del puntaje para separar AP de PA *solo entre placas sin cardiomegalia*; 0.5 = el puntaje no codifica la vista.

Resultado 1: la caja negra detecta mejor

Resultados · línea base



- **ResNet-50**: AUC **0.892**; gana en cada semilla y vista.
- **ICT**: **0.814**; supera al ICT de CheXmask sin red (0.801).
- Al umbral 0.50: sens. 0.918, esp. 0.504.
- El umbral no es el problema: Youden en validación = 0.495–0.497.

Resultado 2: mide bien, aun sin contornos humanos

Variante (147 placas SCR)	Dice corazón	Dice medio	Error ICT	ICC(A,1)
E1a débil, todas	0.936	0.962	0.012	0.948–0.953
E1b débil, RCA ≥ 0.7	0.936	0.961	0.012	0.945–0.951
E1c E1b + 80 humanas	**0.951**	**0.971**	**0.010**	**0.964–0.971**

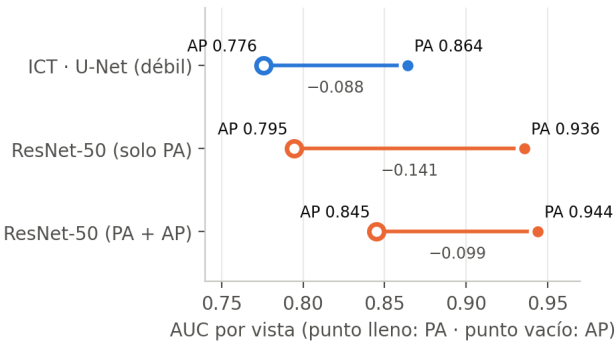
- Filtrar por calidad no cambia nada: solo 110 de 8 776 máscaras bajo RCA 0.7.
- E1c: sesgo de -0.0035 a -0.0005; Bland-Altman $\approx \pm 0.03$.

Paradoja: E1c mide mejor, pero su AUC baja de 0.814 a **0.796**.

Medir mejor no es diagnosticar mejor cuando la etiqueta no es la medida. Además, la mejora se mide en JSRT, el mismo dominio del ajuste.

Resultado 3: el atajo de la proyección AP

Resultados · comparación controlada



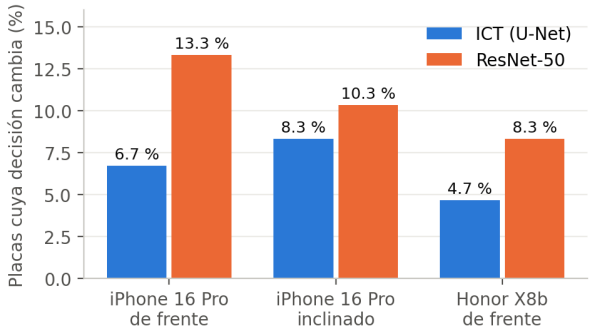
- Todos pierden en AP. La ResNet que solo vio PA pierde **0.141**.
- La ResNet **codifica la vista**: fuga 0.646 (0.710 solo PA).
- En el **ICT** la causa es física (magnificación): esp. AP = 0.356.
- **Corrección con la vista** (reg. log.): fuga **0.691** → **0.493**, esp. AP **0.356** → **0.619**, a costa de 0.004 de AUC.

Resultado 4: 300 fotos con celular



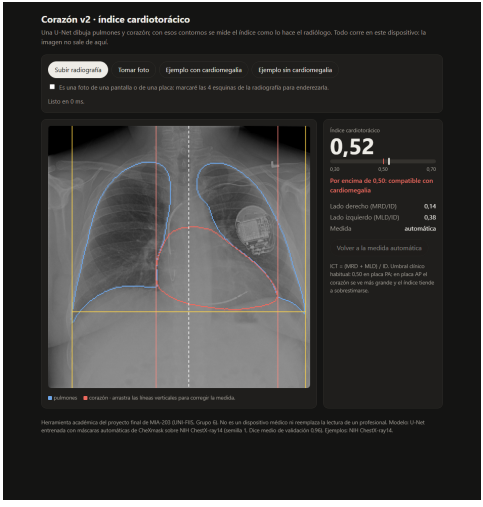
iPhone 16 Pro inclinado: marcas ArUco → homografía → recorte.

AUC: ambos pierden 0.02–0.03.



- El **ICT** cambia de decisión solo cerca del umbral: mediana a **0.013** de 0.50 (0.056 en todas).
- Las degradaciones sintéticas *subestimaron* el efecto real.

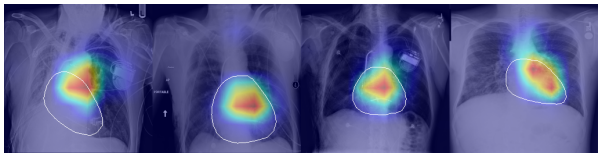
La aplicación: medir en el celular, sin enviar la imagen



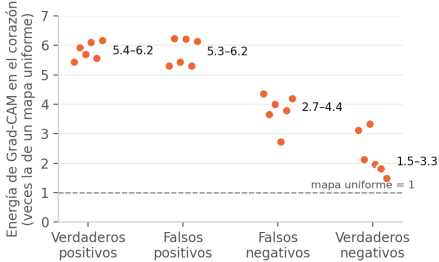
- U-Net exportada a **ONNX** (31 MB), corre en el navegador.
- Verificada contra PyTorch: dif. máx. 2.5×10^{-6}; 100 % de píxeles iguales; mismo ICT que Python.
- Para fotos: el usuario marca 4 esquinas y se endereza.
- Las líneas se **arrastran**: el médico corrige la medida y el ICT cambia.
- 1.7–3.2 s por medición en una laptop.

Grad-CAM mira al corazón, también cuando falla

Interpretabilidad



ResNet-50, semilla 0; blanco: corazón de CheXmask. En la 3.ª se ve el rótulo "PORTABLE" (vista AP).



- Energía en el corazón respecto de un mapa uniforme, por grupo (3 semillas $\times$ 2 vistas).
- Falsos positivos = verdaderos positivos (5.3–6.2 vs. 5.4–6.2).
- El mapa dice *dónde* mira, no *si acertó*.
- Falsos positivos más frecuentes en AP en las 3 semillas.

Discusión: explicar no es lo mismo que medir

Por qué gana la caja negra

- Ve toda la placa; el ICT la reduce a un cociente de anchos.
- La etiqueta del NIH sale del texto del informe, no es "ICT > 0.50": las distribuciones se solapan.
- Aprende de la vista (fuga 0.646): parte de su ventaja puede ser atajo.

Lo que se gana al medir

- Errores con nombre: AP $\rightarrow$ magnificación $\rightarrow$ corrección.
- Con fotos cambia menos decisiones y solo en casos limítrofes.
- El error se ve en la placa y se corrige arrastrando una línea.

E6: lo que el ICT frontal no ve

MRD/ID separa peor que MLD/ID (AUC 0.697 vs. 0.735). Los falsos negativos no esconden un lado derecho grande: su MRD/ID (0.138–0.154) es como el de los verdaderos negativos (0.137–0.148). Para el ventrículo derecho haría falta la placa lateral.

Limitaciones, sesgos e impacto

Responsabilidad

Limitaciones y sesgos

- Etiquetas del NIH extraídas por procesamiento de lenguaje: con ruido.
- Población de EE. UU. y Japón; sin placas peruanas. Umbral 0.50 de poblaciones de llanura.
- Fotos de un monitor, no de placas físicas; una sesión, un operador.
- Referencia dorada: 147 placas JSRT, todas PA.

Impacto y uso responsable

- Apoyo para una segunda lectura, **no un diagnóstico** ni un dispositivo médico.
- La imagen no sale del teléfono.
- Riesgos: aplicar 0.50 a placas AP sin corregir; sesgo de automatización con la caja negra; usarlo en poblaciones no evaluadas.
- Costo: 4.2 h de GPU T4 para todo el proyecto.

Conclusiones y trabajo futuro

Conclusiones

- Una U-Net entrenada solo con máscaras automáticas mide el ICT con ICC **0.945–0.951** (**0.964–0.971** con 80 contornos humanos).
- La **ResNet-50** detecta mejor (**0.892** vs. **0.814**), pero codifica la vista y cambia más decisiones con fotos.
- El ICT falla de forma **predecible y corregible**.
- Sin radiólogo, la elección no es solo de exactitud: es qué error puede revisar quien usa la herramienta.

Trabajo futuro

1. Validar con placas peruanas e ICT medido por radiólogos; umbral por vista y por altitud.
2. Combinar: ResNet como alerta + ICT como explicación revisable.
3. Esquinas automáticas y fotos de placas físicas.
4. Comparar con HybridGNet y modelos de base tipo Transformer.

Código, resultados y app:
github.com/loupv99/corazon-v2