Universidad Nacional de Ingeniería · FIIS · Maestría en Inteligencia Artificial
MIA-203 Redes Neuronales y Aprendizaje Profundo · Examen final

Medir como el radiólogo

Índice cardiotorácico con **U-Net** frente a una **CNN de caja negra** para detectar cardiomegalia

Grupo 6
Juan Sebastian Contreras Avendaño · Junior Francesco Romero Lovera · Luis Muñoz Cañabe
Derly Raúl Oha Quispe · Lourdes Pedraza Palomino

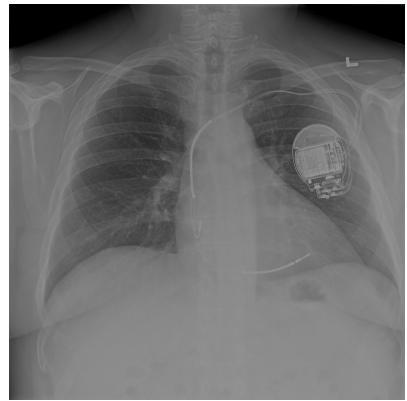
Lima, 7 de noviembre de 2026 · github.com/loupv99/corazon-v2

El problema: ¿el corazón está agrandado?

- La cardiomegalia se sospecha con el **índice cardiotorácico**:

$$\text{ICT} = \frac{\text{ancho del corazón}}{\text{ancho interno del tórax}}$$

- **ICT > 0.50** en placa PA sugiere cardiomegalia.
- Es una *medida*: el radiólogo traza líneas y divide. Sin radiólogo, la placa espera.
- Dos caminos con aprendizaje profundo: **medir** el ICT con contornos o **clasificar** la placa entera.



Placa de prueba de ChestX-ray14 (NIH)

Pregunta y contribuciones

Problema y motivación

¿Una red que **mide** como el radiólogo detecta tan bien
como una red que **clasifica** sin explicar? ¿Y cuál falla mejor?

1. **Comparación controlada medir frente a clasificar**, con las mismas particiones y 3 semillas: U-Net entrenada con *máscaras automáticas* (CheXmask) y evaluada contra *contornos humanos* (SCR).
2. **El atajo de la proyección AP**, medido en ambos enfoques, con una corrección explícita para el ICT y Grad-CAM para la caja negra.
3. **Un conjunto de datos propio**: 300 fotos con celular de 100 radiografías, con marcas ArUco para enderezarlas, y una **aplicación web** que mide el ICT en el teléfono y deja corregir la medida.

Trabajos relacionados

Trabajos relacionados

Trabajo	Qué hace	En qué nos diferenciamos
Ronneberger 2015 · U-Net	Codificador-decodificador con saltos	La usamos para medir, no solo segmentar
He 2016 · ResNet	Conexiones residuales	Línea base de caja negra
Selvaraju 2017 · Grad-CAM	Mapa de dónde mira la red	Lo cuantificamos por acierto y error
Sogancioglu 2020	Segmentación vs. clasificación	Máscaras *automáticas*, vista AP, fotos
Chamveha 2020	ICT como MRD + MLD	Cada lado por separado (E6)
Gaggion 2022, 2024 · HybridGNet, CheXmask	Máscaras con una red de grafos	Las destilamos en una U-Net ligera
Zech 2018 · CheXphoto 2020	Atajos de hospital; fotos de placas	Ambos efectos sobre una *medida*

Fundamento: por qué estas dos arquitecturas

Fundamento teórico

U-Net — medir

- El codificador baja a 1/16 para ver contexto; los **saltos** devuelven el detalle del borde.
- El ICT depende de bordes exactos: un error de 3 px en 256 cambia el ICT en $\sim$0.01.
- Sigmoide por canal: el corazón se superpone a los pulmones.
- Salida **verificable**: contornos que el médico ve.

ResNet-50 — clasificar

- Bloques residuales $y = F(x) + x$: profundidad sin degradación.
- Preentrenada en ImageNet: buen punto de partida con 5 416 placas.
- Ve toda la placa: puede usar señales que el ICT ignora… y atajos.
- Grad-CAM: $L = \mathrm{ReLU}\big(\sum_k \alpha_k A^k\big)$, $\alpha_k = \frac{1}{Z}\sum_{i,j} \frac{\partial y}{\partial A^k_{ij}}$

Datos: tres fuentes, una partición sin fuga

Datos

ChestX-ray14	Placas	Cardio.	AP
Entrenamiento	5 416	1 471	1 829
Validación	1 006	236	357
Prueba (oficial NIH)	2 354	1 069	1 335

- Partición por **paciente** (5 674): nadie aparece en dos particiones.
- Negativos con y sin otros hallazgos: la red no aprende "sano vs. enfermo".
- La vista está asociada a la etiqueta: 43.7 % AP en cardiomegalia frente a 38.5 % sin ella.

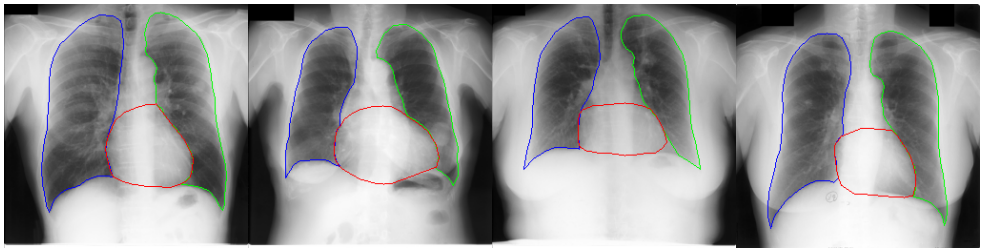
CheXmask (CC BY 4.0)
máscaras *automáticas* de pulmones y corazón para las 8 776 placas; 8 666 con calidad RCA ≥ 0.7.

SCR / JSRT (CC BY 4.0)
contornos *humanos* en 247 placas: 147 de prueba dorada, 80 + 20 para ajuste fino.

Fotos propias
300 fotos de 100 placas de prueba con dos celulares.

Etiquetas débiles, referencia humana

Datos

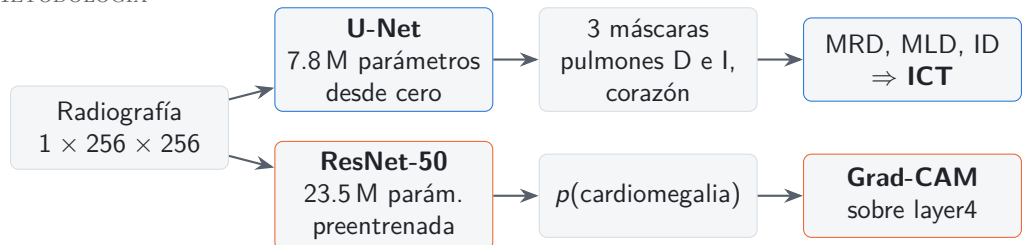


Contornos humanos de SCR rasterizados (azul: pulmón derecho; verde: izquierdo; rojo: corazón)

- La U-Net **aprende** de máscaras de HybridGNet (convoluciones + red de grafos) y se **evalúa** en contornos trazados por personas: una destilación hacia una red que cabe en un navegador.
- Sin volteo horizontal en el aumento: el corazón está a la izquierda del paciente.

Arquitectura del sistema

Metodología



U-Net: 4 niveles (32–256 canales) + cuello de 512; cada bloque = 2 × (conv 3 × 3, BatchNorm, ReLU); sube con conv. transpuesta y concatena el salto; salida 1 × 1 con 3 sigmoides.

ResNet-50: capa final cambiada por una salida; gris repetido en 3 canales; mismas imágenes, partición y aumento que la U-Net.

Formulación: pérdida y medida

Metodología

Segmentación: BCE + Dice promediado por canal

$$\mathcal{L}_{\text{seg}} = \text{BCE}(\hat{y}, y) + 1 - \frac{1}{3}\sum_{c=1}^{3} \frac{2\sum_i \hat{y}_{c,i} y_{c,i} + \epsilon}{\sum_i \hat{y}_{c,i} + \sum_i y_{c,i} + \epsilon}$$

El promedio por canal evita que los pulmones, más grandes, dominen al corazón.

Clasificación: BCE con peso $w_+ = N_-/N_+$

$$\mathcal{L}_{\text{cls}} = -\frac{1}{N}\sum_n \left[w_+ y_n \log p_n + (1-y_n)\log(1-p_n)\right]$$

Del contorno al número

- Umbral 0.5 y mayor componente conexa.
- ID: la fila más ancha entre bordes externos de los pulmones; su centro es la línea media x_m.
- $\text{MRD} = x_m - x_{\text{mín}}$, $\text{MLD} = x_{\text{máx}} - x_m$

$$\text{ICT} = \frac{\text{MRD} + \text{MLD}}{\text{ID}}$$

- Si falta una estructura: *no medible*.

Entrenamiento y costo

Metodología

	U-Net	Ajuste E1c	ResNet-50
Épocas	30	30	12
Lote	16	8	32
Tasa máx.	10^{-3}	2×10^{-4}	3×10^{-4}
Elige época por	Dice val.	Dice 20 humanas	AUC val.

AdamW (decaimiento 10^{-4}), OneCycle, precisión mixta. Aumento: rotación $\pm 10^{\circ}$, escala 0.9–1.1, traslación ± 5 %, brillo/contraste ± 15 %.

- **3 semillas** (0, 1, 2): media $\pm$ D. E.
- Umbral ResNet: Youden en validación. ICT: **0.50 clínico**, sin ajustar.
- La prueba no se usó para elegir nada.

4.2 h de GPU

Kaggle, 2 $\times$ Tesla T4. E5 y E6 en el CPU de una laptop (E5: 35.5 min).

Diseño experimental

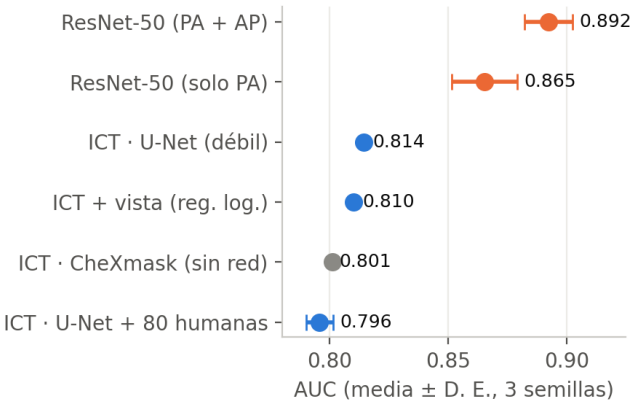
Metodología

Experimento	Qué se compara	Métrica
E1 Ablación de etiquetas	Débiles todas / filtradas RCA ≥ 0.7 / + 80 humanas	Dice en SCR
E2 Línea base	ICT U-Net, ResNet-50, ICT de CheX-mask sin red, reg. log. [ICT, vista]	AUC, sens., esp., F1
E3 Acuerdo clínico	ICT de la U-Net vs. ICT de contornos humanos	ICC(A,1), Bland-Altman
E4 Proyección	AUC por vista; ResNet solo PA; fuga de vista; Grad-CAM	AUC PA/AP, fuga
E5 Fotos	Original vs. 3 condiciones reales + 6 sintéticas	% de decisiones que cambian, AUC
E6 Lado derecho	MRD/ID y MLD/ID por separado	AUC, aciertos vs. errores

Fuga de vista = AUC del puntaje para separar AP de PA *solo entre placas sin cardiomegalia*; 0.5 = el puntaje no codifica la vista.

Resultado 1: la caja negra detecta mejor

Resultados · línea base



- **ResNet-50**: AUC **0.892**, en las 3 semillas y en ambas vistas.
- **ICT**: **0.814**; supera al ICT de CheXmask sin red (0.801).
- Al umbral 0.50: sens. 0.918, esp. 0.504.
- El umbral no es el problema: Youden en validación = 0.495–0.497.

Resultado 2: mide bien, aun sin contornos humanos

Variante (147 placas SCR)	Dice corazón	Dice medio	Error ICT	ICC(A,1)
E1a débil, todas	0.936	0.962	0.012	0.948–0.953
E1b débil, RCA ≥ 0.7	0.936	0.961	0.012	0.945–0.951
E1c E1b + 80 humanas	**0.951**	**0.971**	**0.010**	**0.964–0.971**

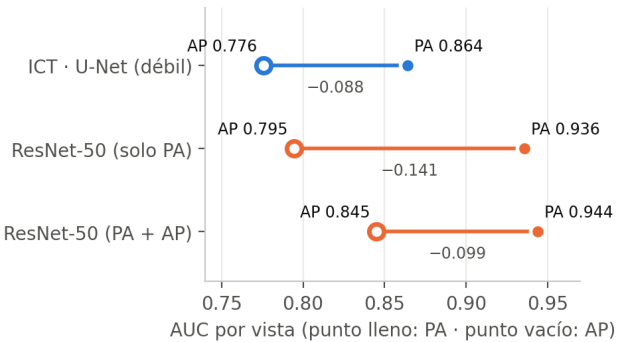
- Filtrar por calidad no cambia nada: solo 110 de 8 776 máscaras bajo RCA 0.7.
- E1c: sesgo de -0.0035 a -0.0005; Bland-Altman $\approx \pm 0.03$.

Paradoja: E1c mide mejor, pero su AUC baja de 0.814 a **0.796**.

Medir mejor no es diagnosticar mejor cuando la etiqueta no es la medida. Además, la mejora se mide en JSRT, el mismo dominio del ajuste.

Resultado 3: el atajo de la proyección AP

Resultados · comparación controlada



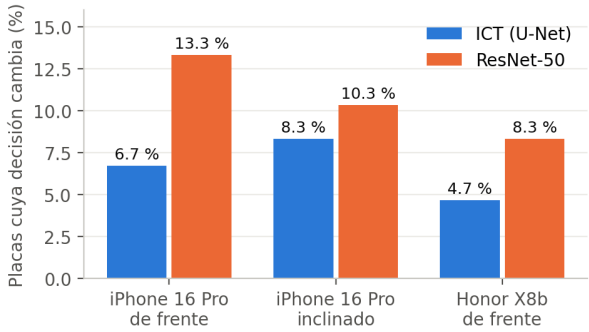
- Todos pierden en AP. La ResNet que solo vio PA pierde **0.141**.
- La ResNet **codifica la vista**: fuga 0.646 (0.710 solo PA).
- En el **ICT** la causa es física (magnificación): esp. AP = 0.356.
- **Corrección con la vista** (reg. log.): fuga **0.691** → **0.493**, esp. AP **0.356** → **0.619**, a costa de 0.004 de AUC.

Resultado 4: 300 fotos con celular



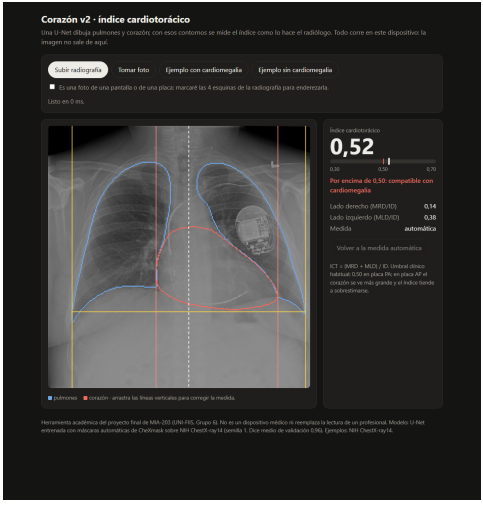
iPhone 16 Pro inclinado: marcas ArUco → homografía → recorte.

AUC: ambos pierden 0.02–0.03.



- El **ICT** cambia de decisión solo cerca del umbral: mediana a **0.013** de 0.50 (0.056 en todas).
- Las degradaciones sintéticas *subestimaron* el efecto real.

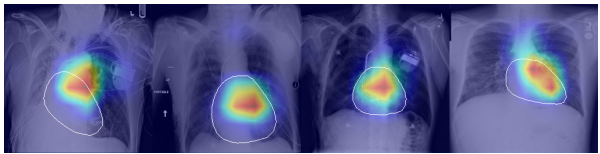
La aplicación: medir en el celular, sin enviar la imagen



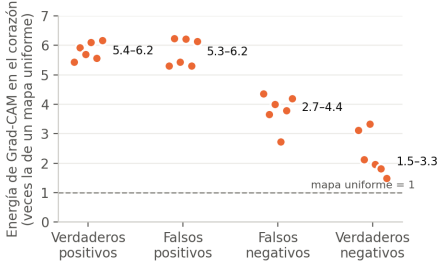
- U-Net exportada a **ONNX** (31 MB), corre en el navegador.
- Verificada contra PyTorch: dif. máx. 2.5×10^{-6}; 100 % de píxeles iguales; mismo ICT que Python.
- Para fotos: el usuario marca 4 esquinas y se endereza.
- Las líneas se **arrastran**: el médico corrige la medida y el ICT cambia.
- 1.7–3.2 s por medición en una laptop.

Grad-CAM mira al corazón, también cuando falla

Interpretabilidad



ResNet-50, semilla 0; blanco: corazón de CheXmask. En la 3.ª se ve el rótulo "PORTABLE" (vista AP).



- Energía en el corazón respecto de un mapa uniforme, por grupo (3 semillas $\times$ 2 vistas).
- Falsos positivos = verdaderos positivos (5.3–6.2 vs. 5.4–6.2).
- El mapa dice *dónde* mira, no *si acertó*.
- Falsos positivos más frecuentes en AP en las 3 semillas.

Discusión: explicar no es lo mismo que medir

Por qué gana la caja negra

- Ve toda la placa; el ICT la reduce a un cociente de anchos.
- La etiqueta del NIH sale del texto del informe, no es "ICT > 0.50": las distribuciones se solapan.
- Aprende de la vista (fuga 0.646): parte de su ventaja puede ser atajo.

Lo que se gana al medir

- Errores con nombre: AP $\rightarrow$ magnificación $\rightarrow$ corrección.
- Con fotos cambia menos decisiones y solo en casos limítrofes.
- El error se ve en la placa y se corrige arrastrando una línea.

E6: lo que el ICT frontal no ve

MRD/ID separa peor que MLD/ID (AUC 0.697 vs. 0.735). Los falsos negativos no esconden un lado derecho grande: su MRD/ID (0.138–0.154) es como el de los verdaderos negativos (0.137–0.148). Para el ventrículo derecho haría falta la placa lateral.

Limitaciones, sesgos e impacto

Responsabilidad

Limitaciones y sesgos

- Etiquetas del NIH extraídas por procesamiento de lenguaje: con ruido.
- Población de EE. UU. y Japón; sin placas peruanas. Umbral 0.50 de poblaciones de llanura.
- Fotos de un monitor, no de placas físicas; una sesión, un operador.
- Referencia dorada: 147 placas JSRT, todas PA.

Impacto y uso responsable

- Apoyo para una segunda lectura, **no un diagnóstico** ni un dispositivo médico.
- La imagen no sale del teléfono.
- Riesgos: aplicar 0.50 a placas AP sin corregir; sesgo de automatización con la caja negra; usarlo en poblaciones no evaluadas.
- Costo: 4.2 h de GPU T4 para todo el proyecto.

Conclusiones y trabajo futuro

Conclusiones

- Una U-Net entrenada solo con máscaras automáticas mide el ICT con ICC **0.945–0.951** (**0.964–0.971** con 80 contornos humanos).
- La **ResNet-50** detecta mejor (**0.892** vs. **0.814**), pero codifica la vista y cambia más decisiones con fotos.
- El ICT falla de forma **predecible y corregible**.
- Sin radiólogo, la elección no es solo de exactitud: es qué error puede revisar quien usa la herramienta.

Trabajo futuro

1. Validar con placas peruanas e ICT medido por radiólogos; umbral por vista y por altitud.
2. Combinar: ResNet como alerta + ICT como explicación revisable.
3. Esquinas automáticas y fotos de placas físicas.
4. Comparar con HybridGNet y modelos de base tipo Transformer.

Código, resultados y app:
github.com/loupv99/corazon-v2