**UNIVERSIDAD NACIONAL DE INGENIERÍA**
FACULTAD DE INGENIERÍA DE SISTEMAS E INDUSTRIAL

# *Medir como el radiólogo: índice cardiotorácico con U-Net frente a una CNN de caja negra para detectar cardiomegalia*

## Examen Final · Proyecto del curso

**Curso:** Redes Neuronales y Aprendizaje Profundo (MIA-203) · Maestría en Inteligencia Artificial

**Autores (Grupo 6):**
Contreras Avendaño, Juan Sebastian
Romero Lovera, Junior
Muñoz Cañabe, Luis
Oha Quispe, Derly Raúl
Pedraza Palomino, Lourdes

Repositorio: github.com/loupv99/corazon-v2

**Noviembre - 2026**

# Contexto y antecedentes

## Del ICT de Danzer (1919) a las máscaras automáticas de CheXmask (2024)

**1919** — **Danzer** define el ICT: si pasa de 0.50, el corazón es sospechoso. Se mide a mano.

**2006** — **SCR**: personas trazan pulmones y corazón en 247 placas JSRT.

**2015–16** — **U-Net** segmenta con pocos datos; **ResNet** entrena redes muy profundas.

**2017** — **ChestX-ray8/14**: 108 948 placas con etiquetas sacadas del informe.

**2020** — **Sogancioglu**: medir gana a clasificar (AUC 0.977 vs. 0.941) con anotación humana.

**2024** — **CheXmask**: 657 566 máscaras automáticas (HybridGNet).

### Y en el Perú

**495**
radiólogos para más de 35 millones

**54.8 %**
de radiólogos y tecnólogos, en Lima

**3 072**
establecimientos en la Red de Telesalud

**La placa ya puede viajar; lo que falta es quien la lea.**

Fuentes: Danzer 1919 · Wang *et al.* 2017 · Sogancioglu *et al.* 2020 · Gaggion *et al.* 2024 · MINSA, vía Panamericana (2025, 2026)

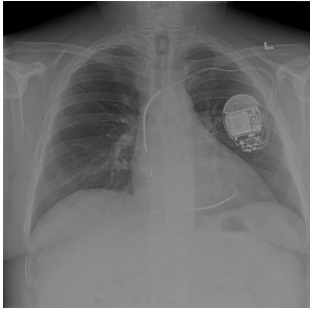
# Planteamiento del problema

**La cardiomegalia se sospecha con una medida que hoy depende del radiólogo**

- La cardiomegalia se sospecha con el **índice cardiotorácico**:

$$\text{ICT} = \frac{\text{ancho del corazón}}{\text{ancho interno del tórax}}$$

- **ICT** $> 0.50$ en placa PA sugiere cardiomegalia.
- Es una *medida*: el radiólogo traza líneas y divide. Sin radiólogo, la placa espera.
- Dos caminos con aprendizaje profundo: **medir** el ICT con contornos o **clasificar** la placa entera.



Placa de prueba de ChestX-ray14 (NIH)

# Pregunta, hipótesis y contribuciones

## Medir como el radiólogo frente a clasificar sin explicar

¿Una red que **mide** como el radiólogo detecta tan bien como una que **clasifica** sin explicar? ¿Y cuál falla mejor?

**Hipótesis:** medir detecta al menos igual, y sus errores se pueden ver y corregir.

1

**Medir frente a clasificar, en igualdad**

Mismas placas, partición y aumento; 3 semillas. U-Net con *máscaras automáticas*, evaluada con *contornos humanos*.

→ **E1, E2, E3**

2

**El atajo de la vista AP**

¿Las dos redes usan la proyección en vez del corazón? Corrección explícita para el ICT; Grad-CAM para la caja negra.

→ **E4, E6**

3

**Datos y aplicación propios**

300 fotos con celular de 100 placas, con marcas ArUco para enderezarlas. App web que mide en el teléfono y deja corregir.

→ **E5**

# Trabajos relacionados (1/2)

## Arquitecturas, explicación visual y datos a gran escala

| Trabajo | Metodología | Principales hallazgos | Aporte al conocimiento | En qué nos diferenciamos |
|---|---|---|---|---|
| **Ronneberger, 2015** U-Net | Codificador-decodificador con saltos; aumento de datos fuerte | Segmenta bien con muy pocas imágenes; ganó ISBI 2015 | Segmentación precisa con pocos datos | **La usamos para medir el ICT**, entrenada con máscaras automáticas |
| **He, 2016** ResNet | Bloques residuales $y = F(x) + x$, hasta 152 capas | 3.57 % de error en ImageNet; 1.er puesto en ILSVRC 2015 | Redes muy profundas que sí se optimizan | ResNet-50 como **caja negra de referencia** |
| **Selvaraju, 2017** Grad-CAM | Gradientes sobre la última capa convolucional, sin reentrenar | Localiza regiones relevantes y revela sesgos del conjunto | Explicación visual para cualquier CNN | **La cuantificamos** en aciertos y en errores |
| **Wang, 2017** ChestX-ray8/14 | 108 948 placas de 32 717 pacientes; etiquetas del informe con PLN | Detecta con etiquetas débiles, pero leer la placa sigue siendo difícil | Primera base pública grande de tórax | Su etiqueta no equivale a ICT $>$ 0.50 (esp. 0.504) |

# Trabajos relacionados (2/2)

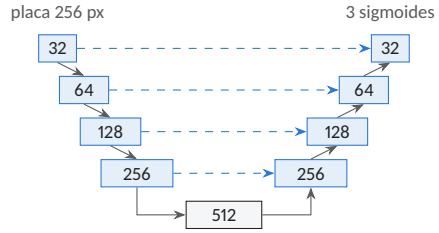
## Cardiomegalia, máscaras anatómicas y robustez

| Trabajo | Metodología | Principales hallazgos | Aporte al conocimiento | En qué nos diferenciamos |
|---|---|---|---|---|
| **Sogancioglu, 2020** | Segmentar (778 anotadas) vs. clasificar (65 000) | AUC 0.977 vs. 0.941 (367 placas, 2 radiólogos) | Medir gana con 100 veces menos anotaciones | Etiqueta del informe y **máscaras automáticas**: gana clasificar |
| **Chamveha, 2020** | U-Net + VGG16; ICT $= (\text{MRD} + \text{MLD})/\text{ID}$ | 76.5 % de medidas aceptadas sin cambios | ICT automático usable en el informe | **MRD y MLD por separado** (E6); vista AP y fotos |
| **Gaggion, 2023–24** HybridGNet, CheXmask | Conv. + grafos; 657 566 máscaras | Contornos plausibles donde otros modelos fallan | Máscaras anatómicas a gran escala | Las **destilamos en una U-Net** para el navegador |
| **Zech, 2018**; **Phillips, 2020** | CNN en 3 hospitales (158 323 placas); fotos con celular | Reconoce el hospital (99.95 %, NIH); CheXphoto: robustez | Atajos del origen; escenario de fotos | Atajo de la **vista AP** en ambos enfoques; fotos propias con ArUco |

# Fundamento teórico

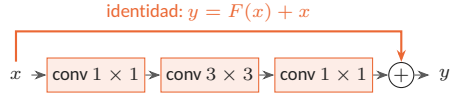
## Una red que localiza bordes frente a una que resume toda la placa

### U-Net — medir




- El ICT depende del borde: 3 px de error en 256 cambian el ICT en $\sim$0.01.
- Salida **verificable**: contornos que el médico ve y corrige.

### ResNet-50 — clasificar




**Grad-CAM** sobre la última capa:

$$L = \mathrm{ReLU}\Big(\sum_k \alpha_k A^k\Big), \quad \alpha_k = \tfrac{1}{Z}\sum_{i,j} \frac{\partial y}{\partial A^k_{ij}}$$

- Preentrenada en ImageNet: buen punto de partida con 5 416 placas.
- Ve toda la placa: puede usar señales que el ICT ignora… y atajos.

# Preparación de datos

## Cuatro fuentes llevadas a un mismo formato de 256 px

| | | | | | |
|---|---|---|---|---|---|
| **ChestX-ray14**<br>NIH · 112 120 placas | 2 776 con cardiomegalia + 6 000 sin ella | Partición por **paciente**; prueba oficial del NIH | PNG → gris → 256 px (promedio de área) | Guarda mm/píxel y vista PA/AP | **8 776** placas |
| **CheXmask**<br>máscaras débiles | CSV de 2 GB leído por partes | RLE → 3 máscaras de 1 024 px | Reducción por área + umbral 0.5 | Calidad RCA e ICT sin red | **8 666** con RCA $\geq$ 0.7 |
| **SCR / JSRT**<br>contornos humanos | 247 contornos trazados a mano | Rasterizar a máscaras | Imágenes JSRT **limpias** (sin contorno dibujado) | Gris invertido si hace falta, comprobado | **100** ajuste · **147** prueba |
| **Fotos propias**<br>E5 | 100 placas: 25 por grupo PA/AP × con/sin | Monitor con 5 marcas ArUco | iPhone de frente e inclinada; Honor de frente | Homografía → 256 px | **300** fotos |

Salida común: arrays de 256 px (pulmón derecho, izquierdo, corazón) + una tabla por placa. Una sola vez, ∼20 min en Kaggle.

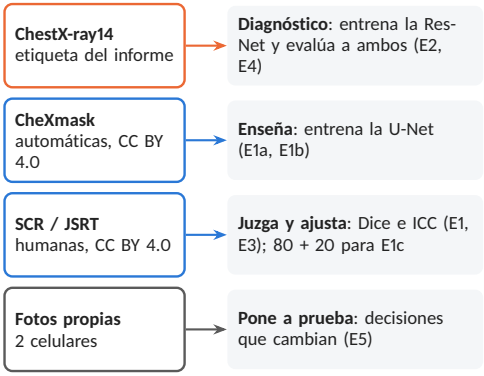
# Datos

## 8 776 placas con partición por paciente; la vista está asociada a la etiqueta

| ChestX-ray14 | Placas | Cardio. | AP |
|---|---|---|---|
| Entrenamiento | 5 416 | 1 471 | 1 829 |
| Validación | 1 006 | 236 | 357 |
| Prueba (oficial NIH) | 2 354 | 1 069 | 1 335 |

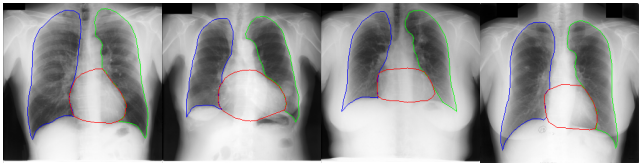
- Partición por **paciente** (5 674): nadie aparece en dos particiones.
- Negativos con y sin otros hallazgos: la red no aprende “sano vs. enfermo”.
- La vista está asociada a la etiqueta: 43.7 % AP en cardiomegalia frente a 38.5 % sin ella.

### Qué papel cumple cada fuente

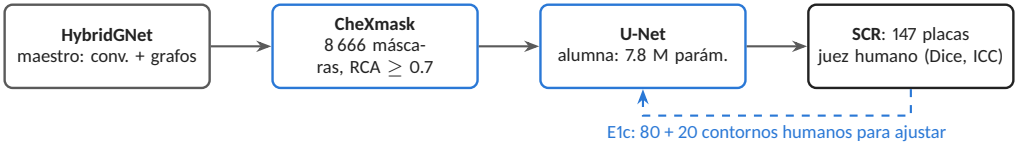


# Etiquetas débiles y referencia humana

## La U-Net aprende de máscaras automáticas y se evalúa contra contornos humanos



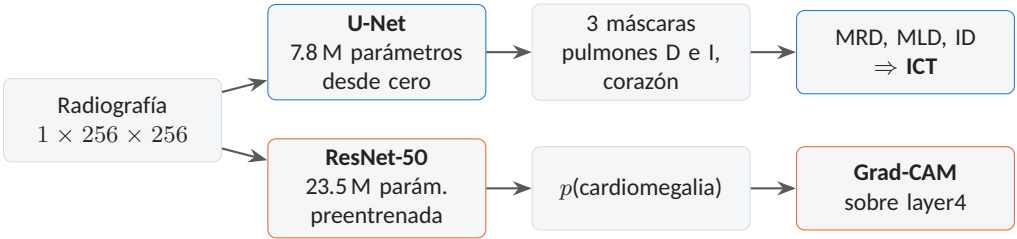
Contornos humanos de SCR rasterizados (azul: pulmón derecho; verde: izquierdo; rojo: corazón)




Una destilación hacia una red que cabe en un navegador. Sin volteo horizontal en el aumento: el corazón está a la izquierda del paciente.

# Arquitectura del sistema

## Dos caminos para la misma radiografía




**U-Net**: 4 niveles (32–256 canales) + cuello de 512; cada bloque = 2 × (conv $3 \times 3$, BatchNorm, ReLU); sube con conv. transpuesta y concatena el salto; salida $1 \times 1$ con 3 sigmoides.

**ResNet-50**: capa final cambiada por una salida; gris repetido en 3 canales; mismas imágenes, partición y aumento que la U-Net.

# Formulación

## De la pérdida de segmentación al índice cardiotorácico

**Segmentación**: BCE + Dice promediado por canal

$$\mathcal{L}_{\text{seg}} = \text{BCE}(\hat{y}, y) + 1 - \frac{1}{3}\sum_{c=1}^{3} \frac{2\sum_i \hat{y}_{c,i} y_{c,i} + \epsilon}{\sum_i \hat{y}_{c,i} + \sum_i y_{c,i} + \epsilon}$$

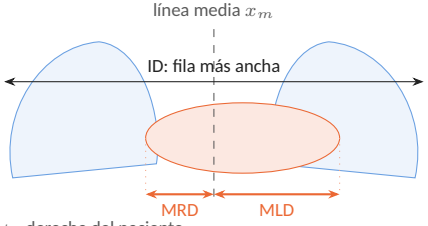
Promediar por canal evita que los pulmones, más grandes, dominen al corazón.

**Clasificación**: BCE con peso $w_+ = N_-/N_+$

$$\mathcal{L}_{\text{cls}} = -\frac{1}{N}\sum_n \left[ w_+ y_n \log p_n + (1 - y_n)\log(1 - p_n) \right]$$

El peso compensa que hay menos placas con cardiomegalia.

### Del contorno al número



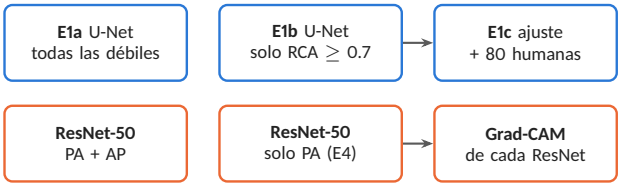

Umbral 0.5 + mayor componente → ID y $x_m$ en la fila más ancha → MRD $= x_m - x_{\text{mín}}$, MLD $= x_{\text{máx}} - x_m$ → $\text{ICT} = \frac{\text{MRD} + \text{MLD}}{\text{ID}}$

Si falta una estructura, la placa queda como *no medible*.

# Entrenamiento y costo computacional

## Cinco configuraciones, tres semillas y 4.2 h de GPU

cada caja $\times$ 3 semillas (0, 1, 2) $\Rightarrow$ media $\pm$ D. E.

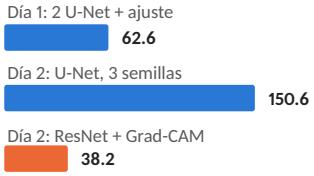



| | U-Net | Ajuste E1c | ResNet-50 |
|---|---|---|---|
| Épocas · lote | 30 · 16 | 30 · 8 | 12 · 32 |
| Tasa máx. | $10^{-3}$ | $2 \times 10^{-4}$ | $3 \times 10^{-4}$ |
| Elige época por | Dice val. | Dice 20 humanas | AUC val. |

AdamW (decaimiento $10^{-4}$), OneCycle, precisión mixta. Aumento: rotación $\pm 10^{\circ}$, escala 0.9–1.1, traslación $\pm 5$ %, brillo/contraste $\pm 15$ %.

### Minutos de GPU

Kaggle, 2 $\times$ Tesla T4




**4.2 h** de GPU

Umbral de la ResNet: Youden en validación. ICT: **0.50 clínico**, sin ajustar. **La prueba no se usó para elegir nada.** E5 y E6, en el CPU de una laptop.

# Diseño experimental

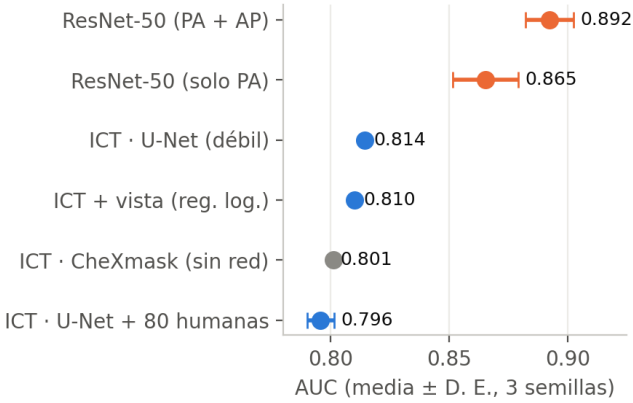
## Seis experimentos, cada uno ligado a una contribución

| Experimento | Qué se compara | Métrica |
|---|---|---|
| E1 Ablación de etiquetas | Débiles todas / filtradas RCA $\geq 0.7$ / + 80 humanas | Dice en SCR |
| E2 Línea base | ICT U-Net, ResNet-50, ICT de CheXmask sin red, reg. log. [ICT, vista] | AUC, sens., esp., F1 |
| E3 Acuerdo clínico | ICT de la U-Net vs. ICT de contornos humanos | ICC(A,1), Bland-Altman |
| E4 Proyección | AUC por vista; ResNet solo PA; fuga de vista; Grad-CAM | AUC PA/AP, fuga |
| E5 Fotos | Original vs. 3 condiciones reales + 6 sintéticas | % de decisiones que cambian, AUC |
| E6 Lado derecho | MRD/ID y MLD/ID por separado | AUC, aciertos vs. errores |

Fuga de vista = AUC del puntaje para separar AP de PA *solo entre placas sin cardiomegalia*; 0.5 = el puntaje no codifica la vista.

# Resultado 1: línea base

## La caja negra detecta mejor: AUC 0.892 frente a 0.814




- **ResNet-50**: AUC **0.892**; gana en cada semilla y vista.
- **ICT**: **0.814**; supera al ICT de CheXmask sin red (0.801).
- Al umbral 0.50: sens. 0.918, esp. 0.504.
- El umbral no es el problema: Youden en validación = 0.495–0.497.

# Resultado 2: acuerdo con contornos humanos

**Sin un solo contorno humano, la U-Net mide con ICC 0.945–0.951**

| Variante (147 placas SCR) | Dice corazón | Dice medio | Error ICT | ICC(A,1) |
|---|---|---|---|---|
| E1a débil, todas | 0.936 | 0.962 | 0.012 | 0.948–0.953 |
| E1b débil, RCA $\geq 0.7$ | 0.936 | 0.961 | 0.012 | 0.945–0.951 |
| E1c E1b + 80 humanas | **0.951** | **0.971** | **0.010** | **0.964–0.971** |

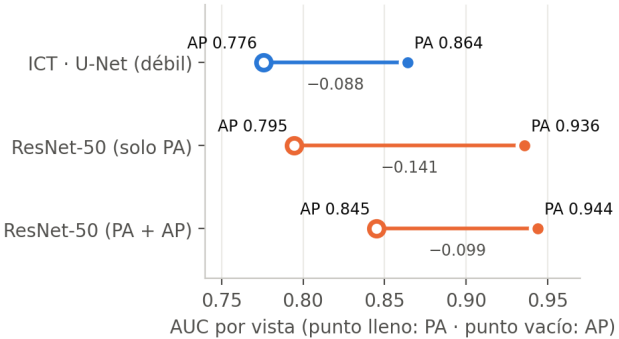
- Filtrar por calidad no cambia nada: solo 110 de 8 776 máscaras bajo RCA 0.7.
- E1c: sesgo de $-0.0035$ a $-0.0005$; Bland-Altman $\approx \pm 0.03$.

Paradoja: E1c mide mejor, pero su AUC baja de 0.814 a **0.796**.

Medir mejor no es diagnosticar mejor cuando la etiqueta no es la medida. Además, la mejora se mide en JSRT, el mismo dominio del ajuste.

# Resultado 3: el atajo de la proyección AP

## Ambos enfoques pierden en AP; solo el ICT se corrige con una fórmula




- Todos pierden en AP. La ResNet que solo vio PA pierde **0.141**.
- La ResNet **codifica la vista**: fuga 0.646 (0.710 solo PA).
- En el **ICT** la causa es física (magnificación): esp. AP = 0.356.
- **Corrección con la vista** (reg. log.): fuga **0.691** → **0.493**, esp. AP **0.356** → **0.619**, a costa de 0.004 de AUC.

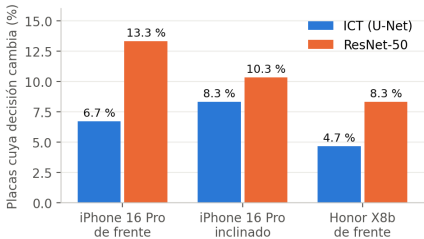
# Resultado 4: fotos con celular

## El ICT cambia de decisión en menos placas y solo cerca del umbral




iPhone 16 Pro inclinado: marcas ArUco → homografía → recorte.

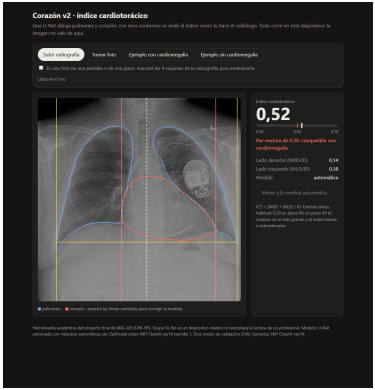
AUC: ambos pierden 0.02–0.03.




- El **ICT** cambia de decisión solo cerca del umbral: mediana a **0.013** de 0.50 (0.056 en todas).
- Las degradaciones sintéticas *subestimaron* el efecto real.

# La aplicación

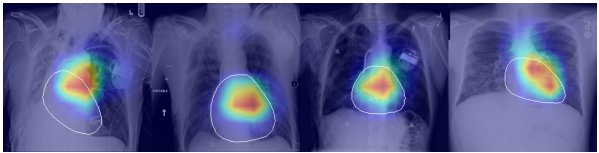
## Medir en el celular, sin enviar la imagen



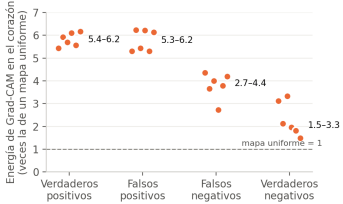

- U-Net exportada a **ONNX** (31 MB), corre en el navegador.
- Verificada contra PyTorch: dif. máx. $2.5 \times 10^{-6}$; 100 % de píxeles iguales; mismo ICT que Python.
- Para fotos: el usuario marca 4 esquinas y se endereza.
- Las líneas se **arrastran**: el médico corrige la medida y el ICT cambia.
- 1.7–3.2 s por medición en una laptop.

# Interpretabilidad: Grad-CAM

## El mapa mira al corazón, también cuando la red se equivoca



ResNet-50, semilla 0; blanco: corazón de CheXmask. En la 3.ª se ve el rótulo “PORTABLE” (vista AP).




- Energía en el corazón respecto de un mapa uniforme, por grupo (3 semillas × 2 vistas).
- Falsos positivos = verdaderos positivos (5.3–6.2 vs. 5.4–6.2).
- El mapa dice *dónde* mira, no *si acertó*.
- Falsos positivos más frecuentes en AP en las 3 semillas.

# Discusión

## Explicar no es lo mismo que medir

### Por qué gana la caja negra

- Ve toda la placa; el ICT la reduce a un cociente de anchos.
- La etiqueta del NIH sale del texto del informe, no es "ICT $>$ 0.50": las distribuciones se solapan.
- Aprende de la vista (fuga 0.646): parte de su ventaja puede ser atajo.

### Lo que se gana al medir

- Errores con nombre: AP $\rightarrow$ magnificación $\rightarrow$ corrección.
- Con fotos cambia menos decisiones y solo en casos limítrofes.
- El error se ve en la placa y se corrige arrastrando una línea.

## E6: lo que el ICT frontal no ve

MRD/ID separa peor que MLD/ID (AUC 0.697 vs. 0.735). Los falsos negativos no esconden un lado derecho grande: su MRD/ID (0.138–0.154) es como el de los verdaderos negativos (0.137–0.148). Para el ventrículo derecho haría falta la placa lateral.

# Limitaciones, sesgos e impacto

## Una herramienta de apoyo, no un diagnóstico

### Limitaciones y sesgos

- Etiquetas del NIH extraídas por procesamiento de lenguaje: con ruido.
- Población de EE. UU. y Japón; sin placas peruanas. Umbral 0.50 de poblaciones de llanura.
- Fotos de un monitor, no de placas físicas; una sesión, un operador.
- Referencia dorada: 147 placas JSRT, todas PA.

### Impacto y uso responsable

- Apoyo para una segunda lectura, **no un diagnóstico** ni un dispositivo médico.
- La imagen no sale del teléfono.
- Riesgos: aplicar 0.50 a placas AP sin corregir; sesgo de automatización con la caja negra; usarlo en poblaciones no evaluadas.
- Costo: 4.2 h de GPU T4 para todo el proyecto.

# Conclusiones y trabajo futuro

**Lo valioso es qué error puede revisar quien usa la herramienta**

- Una U-Net entrenada solo con máscaras automáticas mide el ICT con ICC **0.945–0.951** (**0.964–0.971** con 80 contornos humanos).
- La **ResNet-50** detecta mejor (**0.892** vs. **0.814**), pero codifica la vista y cambia más decisiones con fotos.
- El ICT falla de forma **predecible y corregible**.
- Sin radiólogo, la elección no es solo de exactitud: es qué error puede revisar quien usa la herramienta.

### Trabajo futuro

1. Validar con placas peruanas e ICT medido por radiólogos; umbral por vista y por altitud.
2. Combinar: ResNet como alerta + ICT como explicación revisable.
3. Esquinas automáticas y fotos de placas físicas.
4. Comparar con HybridGNet y modelos de base tipo Transformer.

Código, resultados y app:
github.com/loupv99/corazon-v2